Predicting Poverty: análisis descriptivo y modelos

Maria Jose Perez, Juan Manuel Lozano, Samuel Suárez Valle

26 de octubre de 2026

1. Datos

Se usa la muestra de entrenamiento de la GEIH 2018 (DANE): 543.103 personas en 164.958 hogares. Un hogar es pobre cuando su ingreso per cápita de la unidad de gasto (con arriendo imputado) es menor que la línea de pobreza de su dominio. El 20,0 % de los hogares y el 25,1 % de las personas son pobres.

2. Estadísticas descriptivas

El Cuadro 1 compara las medias de las características de las personas pobres y no pobres. La diferencia es la media de los pobres menos la de los no pobres, y el p-valor viene de una prueba t de diferencia de medias. Las variables de educación y de tenencia de vivienda son dummies por categoría, así que su media es la proporción de personas en esa categoría.

3. Visualización

Las figuras relacionan el ingreso per cápita con cada variable. La línea roja punteada es la mediana de la línea de pobreza ($280.072); la línea varía por dominio, por lo que se usa la mediana como referencia.

Cuadro 1: Estadísticas descriptivas por condición de pobreza

Variable	No pobres	Pobres	Diferencia	p-valor
mujer	0.525	0.541	0.016	0.000
afiliado_salud	0.941	0.906	-0.035	0.000
ocupado	0.508	0.304	-0.204	0.000
educ_ninguno	0.041	0.093	0.052	0.000
educ_preescolar	0.026	0.040	0.014	0.000
educ_primaria	0.232	0.343	0.111	0.000
educ_secundaria	0.166	0.230	0.064	0.000
educ_media	0.240	0.202	-0.039	0.000
educ_superior	0.295	0.092	-0.203	0.000
educ_no_sabe	0.000	0.000	0.000	0.289
vivienda_propia_pagada	0.427	0.294	-0.133	0.000
vivienda_propia_pagando	0.041	0.016	-0.025	0.000
vivienda_arriendo	0.353	0.414	0.061	0.000
vivienda_usufructo	0.145	0.159	0.014	0.000
vivienda_sin_titulo	0.032	0.115	0.082	0.000
vivienda_otra	0.001	0.001	0.001	0.000
Estrato1	3.122	2.126	-0.996	0.000
tamano_empresa	2.152	0.642	-1.510	0.000
anos	35.651	27.303	-8.347	0.000
meses_empresa	43.769	25.511	-18.258	0.000
horas_trabajo_semana	45.421	41.735	-3.687	0.000
cuartos_hogar	3.724	3.212	-0.512	0.000
cuartos_dormir	2.341	2.203	-0.138	0.000
arriendo_estimado	599617.307	277717.379	-321899.928	0.000
prop_edad_trabajar	0.856	0.731	-0.125	0.000

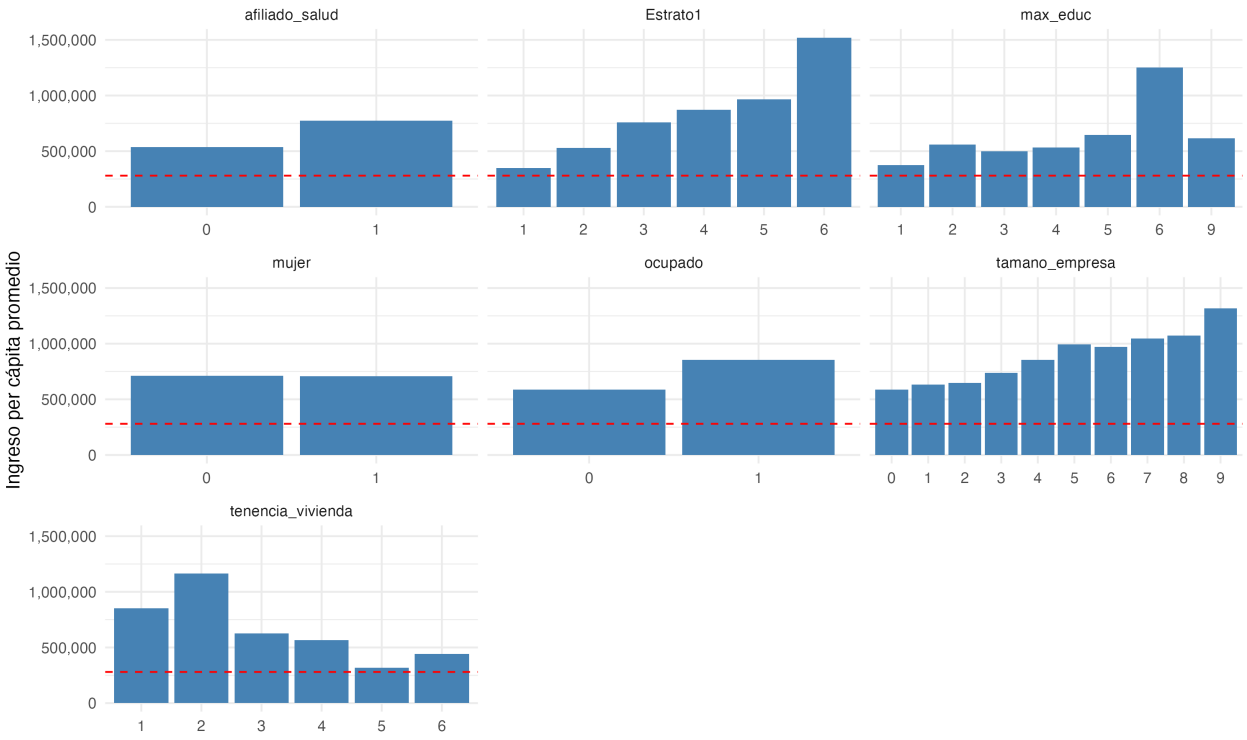


Figura 1: Ingreso per cápita promedio por categoría de las variables dummies y categóricas.

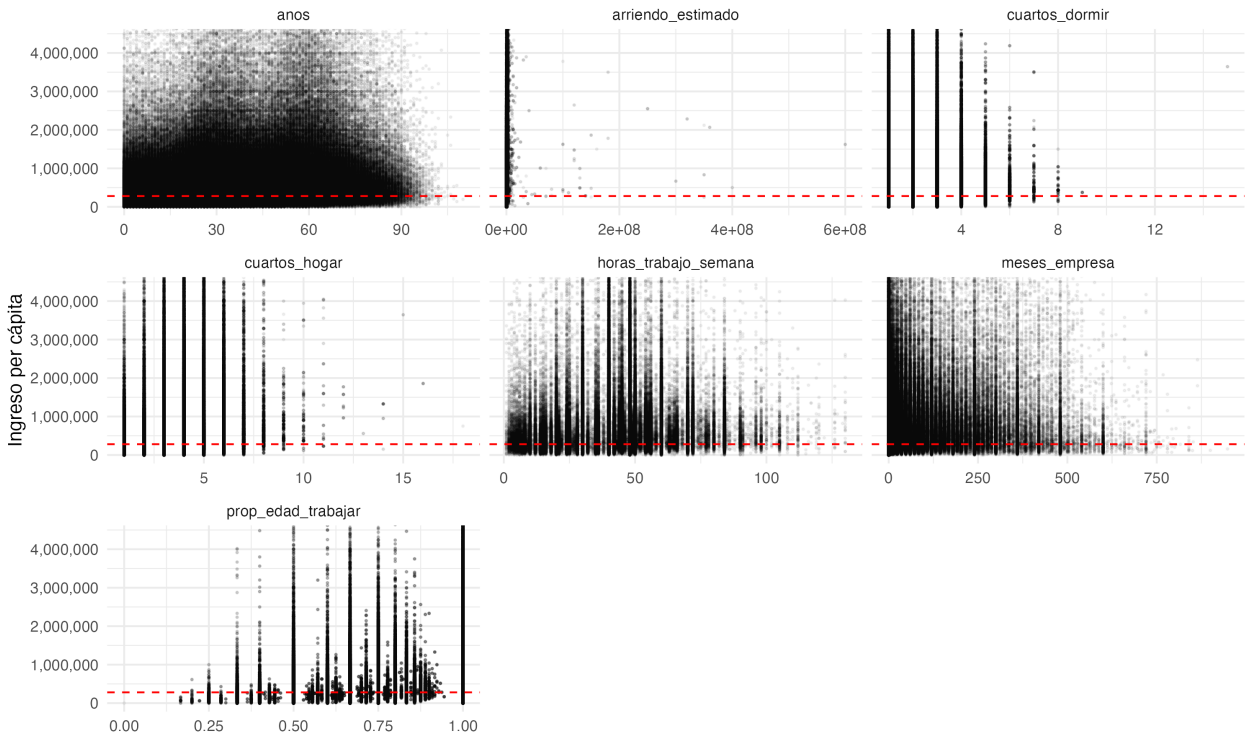


Figura 2: Ingreso per cápita frente a las variables continuas. El eje y se corta en el percentil 99 del ingreso ($4.400.000).

4. Modelos

4.1. Evaluación

Todos los modelos se evalúan igual, así que sus F_1 son comparables:

- **Validación cruzada por hogar:** 10 folds construidos sobre los hogares (`set.seed(123)`), de modo que todas las personas de un hogar quedan en el mismo fold.
- **Predicción por hogar:** el modelo predice la probabilidad de cada persona; la probabilidad del hogar es el promedio de los log odds, $\log(p/(1-p))$, de sus miembros. El hogar se clasifica como pobre si esa probabilidad supera el umbral.
- **Métrica:** F_1 sobre los hogares del fold de validación, promediado entre los 10 folds. El umbral se elige en la misma validación cruzada, por lo que el F_1 reportado es levemente optimista.

4.2. Mejores modelos

Naive Bayes, CART y XGBoost con `x1` usan las mismas 16 variables: `anos`, `anos_educ_imp`, `mujer`, `ocupado`, `afiliado_salud`, `regimen_salud`, `actividad_sem_`

pasada, log_meses_empresa, tamano_empresa, posicion_ocupacional, horas_trabajo_semana, arriendo_pc_sobre_lp, prop_ocupados_hogar, tenencia_vivienda, recibio_arriendos_pensiones y ayudas_instituciones. Las categóricas con códigos del DANE y las dummies entran como factores (en XGBoost, como una dummy por nivel). Los conjuntos x2 y x3 de XGBoost se describen en la Sección 4.3.

Cuadro 2: Mejores modelos por validación cruzada.

Modelo	Script	Hiperparámetros	Umbral	F_1
Naive Bayes	03_naive_bayes.r	laplace = 0	0,42	0,675
CART	04_carts.r	cp = 0,000025; gini; upsampling dentro de cada fold	0,61	0,670
XGBoost (x1)	05_xgboost.r	500 rondas; profundidad 6; eta = 0,1; min_child_weight = 50	0,29	0,693
XGBoost (x3)	05_xgboost.r	500 rondas; profundidad 6; eta = 0,1; min_child_weight = 50	0,32	0,706
XGBoost por hogar	05b_xgboost_hogar.r	categóricas nativas; eta = 0,02; profundidad 8; min_child_weight = 50; colsample = 0,5; ingreso predicho (Tweedie) y modelo por persona con todas las preguntas; combinado con la regresión del ingreso (70/30)	0,39	0,778

Las predicciones de test están en output/submissions/: NB_laplace_0_threshold_042.csv (naive Bayes), CART_up_cp_0000025_threshold_061.csv (CART), XGB_x1_nrounds_500_depth_6_eta_01_threshold_029.csv y XGB_x3_nrounds_500_depth_6_eta_01_threshold_032.csv (XGBoost por persona) y XGBH_nativo_comb_G_eta002_depth6_col08_V4_mas_V4t_todo2_mas_V4f_af_depth8_mcw50_col05_V4w_R_G_eta002_depth6_col08_V4_mas_V4t_todo2_peso_w07_threshold_039.csv (XGBoost por hogar, con CODIFICACION=nativo). Todas se regeneran al correr cada script, con semilla fija.

4.3. XGBoost por persona

05_xgboost.r estima XGBoost con caret y la misma evaluación por hogar. Como el método "xgbTree" de caret no funciona con xgboost 3, el script define el modelo para caret con los mismos siete hiperparámetros (xgb_caret); para cada combinación estima un solo modelo con el mayor nrounds y evalúa los menores con sus primeros árboles. El xgboost de CRAN para macOS no usa varios núcleos, así que los folds se estiman en paralelo (4 a la vez) y cada modelo fija su semilla (seed = 123).

La grilla (`grid_xgb`) tiene 16 combinaciones: `nrounds` $\in \{250, 500\}$, profundidad $\in \{4, 6\}$, `eta` $\in$ {0,05; 0,1} y `min_child_weight` $\in \{10, 50\}$, con `colsample_bytree` = 0,8 y `subsample` = 0,63. Una grilla ampliada (hasta 1.500 rondas y profundidad 10) no mejoró el F_1 (0,6934 frente a 0,6929): con estas variables el modelo ya está en su techo.

Los conjuntos de variables son `x1` (las 16 de arriba); `x2`, que agrega `educ_max_adultos`, `linea_pobreza`, `cuartos_dormir`, `prop_dependientes` y `personas_hogar` (las más importantes del CART con todas las variables); y `x3`, que además agrega `dominio`, `depto` y `cabecera`. Cada uno se estimó con tres bases: la original, la aumentada (hogares pobres replicados hasta balancear las clases) y una sin el 10 % de hogares más ricos en el entrenamiento (la validación sí los incluye).

Cuadro 3: XGBoost por persona: F_1 de validación cruzada por conjunto de variables y base (en paréntesis, el umbral).

Conjunto	Base original	Base aumentada	Sin el 10 % más rico
`x1` (16 variables)	0,693 (0,29)	0,693 (0,64)	0,694 (0,29)
`x2` (21 variables)	0,702 (0,32)	0,702 (0,64)	0,702 (0,32)
`x3` (24 variables)	0,706 (0,32)	0,706 (0,63)	0,706 (0,33)

A diferencia del CART, XGBoost sí aprovecha las variables del hogar y la ubicación: `x3` mejora el F_1 en 0,013 frente a `x1`. La base no cambia el resultado: con la base aumentada el modelo da probabilidades más altas y el umbral óptimo sube en la misma proporción (de 0,32 a 0,63), y quitar a los hogares más ricos (ninguno es pobre) no le quita ni le agrega información útil. Las variables con más ganancia en `x3` son `arriendo_pc_sobre_lp` (31 %), `prop_ocupados_hogar` (24 %), `regimen_salud` (14 %), `educ_max_adultos` (7 %) y `tenencia_vivienda` (6 %).

4.4. XGBoost por hogar

`05b_xgboost_hogar.r` cambia la unidad del modelo: una fila por hogar, con la base de agregados de `01b_bases_hogar.r` (94 variables). Se usan los mismos 5 folds y la misma forma de calcular el F_1 que los modelos logit y LightGBM del equipo, para que los resultados sean comparables. Las variables que usan `pobre` o el ingreso (tasa de pobreza del oficio, ingreso predicho por persona y probabilidad por persona) se estiman con validación cruzada anidada: las del fold que se evalúa nunca usan su propia etiqueta. Cada modelo usa parada temprana (100 rondas) en su fold.

Cuadro 4: XGBoost por hogar: F_1 de validación cruzada (5 folds).

Prueba	Umbral	F_1
H0: base por hogar (94 variables)	0,38	0,7528
H1: + factor de expansión, mejor ocupado, oficio e ingreso predicho	0,36	0,7571
H2: + `educ_max_adultos` y coeficientes de variación	0,33	0,7568
H6: + productos, razones y variables relativas al dominio	0,37	0,7577
H7: + probabilidad por persona (stacking)	0,37	0,7589
Mejores hiperparámetros (`eta` 0,02; profundidad 6)	0,36	0,7598
Solo las 75 variables con más ganancia	0,39	0,7603
+ predicción de la regresión como variable (stacking)	0,37	0,7590
+ combinaciones de las variables más importantes	0,39	0,7593
+ logaritmos y cuadrados	0,37	0,7588
Regresión de log(ingreso / línea) ($R^2 = 0{,}70$)	0,34	0,7533
Combinación: clasificador, regresión y modelo por persona	0,36	0,7600

Modelar el hogar directamente es el mayor salto de todo el trabajo: de 0,706 (XGBoost por persona) a 0,753 con las mismas herramientas. Encima de eso, lo que más aporta es el ingreso predicho y el stacking con el modelo por persona, que juntos concentran el 84 % de la ganancia del mejor modelo. La base aumentada empeora el resultado (0,7536), la base sin los hogares más ricos lo deja igual (0,7592) y combinar con naive Bayes no aporta (su peso óptimo es 0). Tampoco ayudan más combinaciones no lineales de las variables más importantes ni sus logaritmos y cuadrados: XGBoost ya arma esas combinaciones con sus árboles, y una transformación monótona da los mismos cortes que la variable original.

Cuadro 5: XGBoost por hogar: F_1 de validación cruzada según cómo entran las variables categóricas.

Prueba	Códigos enteros	One-hot	Nativas
H0: base por hogar	0,7528	0,7532	0,7534
H1: + ingreso predicho y otras	0,7571	0,7589	0,7596
H7: + stacking por persona	0,7589	0,7601	0,7600
Mejor clasificador	0,7598	0,7605	0,7612
75 variables	0,7603	0,7591	0,7609
20 variables (afinado)	0,7553	0,7594	0,7580

Hasta aquí las categóricas (dominio, departamento, oficio, posición ocupacional, etc.) entraban como códigos enteros, como en el modelo LightGBM del equipo; LightGBM los trata como categorías, pero XGBoost los toma como números ordenados. El Cuadro 5 compara esa codificación con una variable dicotómica por nivel (one-hot) y con las categóricas nativas

de XGBoost. Las dos alternativas mejoran casi todas las pruebas, y el mejor modelo pasa de 0,7598 a 0,7612 con categóricas nativas. La ganancia viene sobre todo de los modelos por persona del ingreso predicho y del stacking (con el oficio, de 84 niveles): en la base por hogar sola (H0) la diferencia es de apenas 0,0005. Estandarizar las variables numéricas de la base por hogar no cambia nada (0,7608 frente a 0,7612): una transformación afín da los mismos cortes.

Cuadro 6: XGBoost por hogar: variables nuevas sobre el mejor clasificador (categóricas nativas, 130 variables). F_1 con el umbral escogido en los mismos folds y con el umbral honesto.

Prueba	F_1	F_1 honesto
Mejor clasificador	0,7612	0,7610
Ingreso predicho afinado (en vez del original)	0,7617	0,7613
Ingreso predicho con variables del hogar	0,7615	0,7611
Ingreso laboral y no laboral por separado	0,7615	0,7613
Ingreso predicho afinado + el original	0,7622	0,7622
+ probabilidad de ser indigente por persona	0,7607	0,7605
+ índices (promedio de variables estandarizadas)	0,7605	0,7599
+ índices supervisados (logit de `pobre`)	0,7607	0,7602
+ los dos tipos de índices	0,7610	0,7610
Todo junto	0,7619	0,7616

El Cuadro 6 prueba tres ideas más. Primero, mejorar el ingreso predicho por persona, que es la segunda fuente de ganancia del modelo: afinar sus hiperparámetros (`eta` 0,05, profundidad 10), darle además variables del hogar, o predecir por separado el ingreso laboral y el no laboral. Las tres versiones predicen un poco mejor el ingreso del hogar (R^2 de 0,520 a 0,523–0,534), pero el F_1 sube poco; lo que más ayuda es usar la versión afinada junto a la original (0,7622, +0,001, el límite de lo que se distingue del ruido). Segundo, un modelo por persona de indigencia, que no aporta: la probabilidad de ser pobre ya contiene esa información. Tercero, índices que resumen variables débiles del mismo tema (informalidad del empleo, capital humano, vivienda, ingresos no laborales y dependencia), ya sea como promedio de las variables estandarizadas o como la predicción de un logit de `pobre`. En el mejor modelo no aportan: con 130 variables y miles de árboles, el boosting ya suma esas señales débiles. Solo ayudan algo en un modelo de 20 variables, donde esas señales no están (0,7590 frente a 0,7580; honesto 0,7590 frente a 0,7576), pero sin llegar al modelo completo.

Cuadro 7: XGBoost por hogar: preguntas que no usaba ningún modelo, modelo por persona afinado, cortes de ingreso y random forest, sobre el mejor modelo anterior.

Prueba	F_1	F_1 honesto
Ingreso predicho afinado + el original	0,7622	0,7622
+ modelo por persona afinado	0,7625	0,7622
+ modelo por persona con las preguntas no usadas	0,7656	0,7649
+ ingreso predicho con las preguntas no usadas	0,7714	0,7708
+ probabilidad de ingreso menor a 0,8 y 1,25 líneas	0,7675	0,7675
Todo junto	0,7715	0,7708
Random forest con las mismas variables	0,7686	0,7684
XGBoost + random forest	0,7717	0,7717

Una revisión de las variables mostró 16 preguntas por persona que están en test y que ningún modelo usaba: pagos en especie, posición en el segundo trabajo, búsqueda de más horas o de otro trabajo, posición en el último trabajo e ingresos por trabajo de desocupados e inactivos. Con ellas, el ingreso predicho por persona pasa de un R^2 de 0,942 a 0,982 (el del ingreso del hogar, de 0,52 a 0,62), sobre todo porque identifican quién recibe ingresos sin estar ocupado, y el F_1 sube a 0,7714 (Cuadro 7): el mayor salto desde pasar a nivel hogar. Las preguntas tienen la misma frecuencia y distribución en train y en test, así que no hay fuga de información. Afinar el modelo por persona sin ellas no cambia nada, y las probabilidades de estar por debajo de 0,8 y 1,25 veces la línea ayudan menos que el ingreso. Un random forest (`ranger`, 500 árboles, `mtry` 30) con las mismas variables llega a 0,7686, y combinado con XGBoost a 0,7717, una diferencia dentro del ruido.

El análisis de errores del mejor modelo muestra dónde está el límite: el 30 % de los errores ocurre en hogares cuyo ingreso está a menos de 10 % de la línea (el 7 % de los hogares), y el 82 % a menos de 50 %. Justo al lado de la línea el modelo se equivoca en 40–46 % de los hogares, mientras que con ingresos de más del doble de la línea casi no se equivoca (0,6 %). Ningún grupo (ciudad, tamaño del hogar, ocupados, tenencia, sexo del jefe) concentra errores de forma llamativa.

Cuadro 8: XGBoost por hogar: pruebas para los hogares cerca de la línea y ajustes finales, sobre el mejor modelo del cuadro anterior ("todo junto").

Prueba	F_1	F_1 honesto
Todo junto (cuadro anterior)	0,7715	0,7708
Más peso a los hogares cerca de la línea (mejor de 4)	0,7712	0,7703
Regresión del ingreso con las variables nuevas (R^2 = 0,835)	0,7684	0,7684
+ ingreso predicho con las preguntas no usadas, afinado	0,7731	0,7721
con profundidad 8, `min_child_weight` 50, `colsample` 0,5	0,7733	0,7724
solo las 75 variables con más ganancia	0,7727	0,7721
combinado con random forest	0,7734	0,7734
con un modelo especialista para los hogares dudosos	0,7726	0,7726

Como la mayoría de los errores está cerca de la línea, el Cuadro 8 prueba dos formas de concentrar el modelo en esos hogares, usando el ingreso real solo para entrenar: darles más peso en el entrenamiento y un segundo modelo, entrenado solo con los hogares a los que el primero da una probabilidad intermedia (entre 0,10 y 0,85), que vuelve a predecirlos. Ninguna ayuda: lo que queda cerca de la línea no se distingue con estas variables. Lo que sí suma algo es afinar el ingreso predicho con las preguntas nuevas (con variables del hogar y por componentes, R^2 por hogar de 0,62 a 0,63) y usarlo junto al anterior, con lo que el mejor modelo llega a 0,7733. Los hiperparámetros, la selección de variables y la combinación con random forest o con la regresión cambian el F_1 en menos de 0,001.

Para descartar que la mejora dependa de la partición en folds, el mejor modelo y el anterior a las preguntas nuevas se estimaron con otras dos particiones, recalculando todas las variables de la validación cruzada anidada. El mejor modelo les gana por 0,011, 0,012 y 0,012 en las tres particiones, y su F_1 es de 0,7733, 0,7749 y 0,7735.

Cuadro 9: XGBoost por hogar: arriendo imputado, ingreso predicho con pérdida Tweedie y combinaciones, sobre el mejor modelo del cuadro anterior (F_1 0,7733).

Prueba	F_1	F_1 honesto
+ ingreso predicho más arriendo imputado (como `Ingpcug`)	0,7741	–
+ ingreso predicho con pérdida Tweedie	0,7772	0,7772
combinado con la regresión del ingreso (70/30)	0,7775	0,7775
combinado con random forest	0,7773	0,7770
combinado con el logit lasso del equipo	0,7772	0,7772
Logit lasso con interacciones (equipo, `06_logit_interacciones.r`)	0,7451	0,7449

El objetivo se define con el ingreso per cápita de la unidad de gasto *con arriendo imputado*:

el DANE suma a los hogares que no pagan arriendo (propietarios y usufructuarios) lo que pagarían por su vivienda. Esa regla se puede reconstruir con variables que están en test (tenencia, arriendo estimado y cuota de amortización): coincide con el arriendo imputado del DANE en el 98,4 % de los hogares de train, y por ella 5,5 % de los hogares no son pobres. Con ella, `01_data_cleaning.r` crea `arriendo_imputado`, y el modelo recibe el ingreso predicho más el arriendo imputado, por persona y línea, como en la definición de pobreza. Aporta poco (0,7741): el modelo ya combinaba el ingreso predicho, el arriendo y la tenencia.

Lo que sí mejora es cambiar la pérdida del modelo del ingreso por persona. Con error cuadrático sobre el logaritmo del ingreso, la predicción de cada persona se acerca a la mediana, y al sumar a los miembros del hogar el ingreso queda subestimado. La pérdida Tweedie (de XGBoost, para variables con muchos ceros y valores positivos asimétricos, entre la Poisson y la Gamma) predice la media del ingreso en pesos. Con potencia 1,2 y un modelo para el ingreso laboral y otro para el no laboral, el R^2 del ingreso del hogar pasa de 0,63 a 0,66 y el F_1 a 0,7772 (+0,004). El clasificador sigue siendo el mismo XGBoost; solo cambia la pérdida del modelo auxiliar. Combinado con la regresión del ingreso (70 % clasificador, 30 % regresión) llega a 0,7775, el mejor resultado. Con otras dos particiones en folds da 0,7784 y 0,7767, y le gana al modelo anterior a las preguntas nuevas por 0,015 en las tres. El logit lasso del equipo, que usa los mismos folds, no suma en la combinación (su peso óptimo es 0): con una correlación de 0,92 con XGBoost en log odds, se equivoca en los mismos hogares.

Dos verificaciones dan una idea de qué tan confiables son estas diferencias. Con el umbral escogido de forma honesta (con los otros 4 folds), el F_1 del mejor modelo baja solo de 0,7598 a 0,7593. Y con otras tres particiones en folds, el F_1 del mejor modelo varía con una desviación estándar de 0,0003, y su mejora sobre H1 es de 0,0025 en promedio, positiva en las cuatro: las diferencias de menos de 0,001 entre modelos son ruido.

4.5. Estructura del modelo final

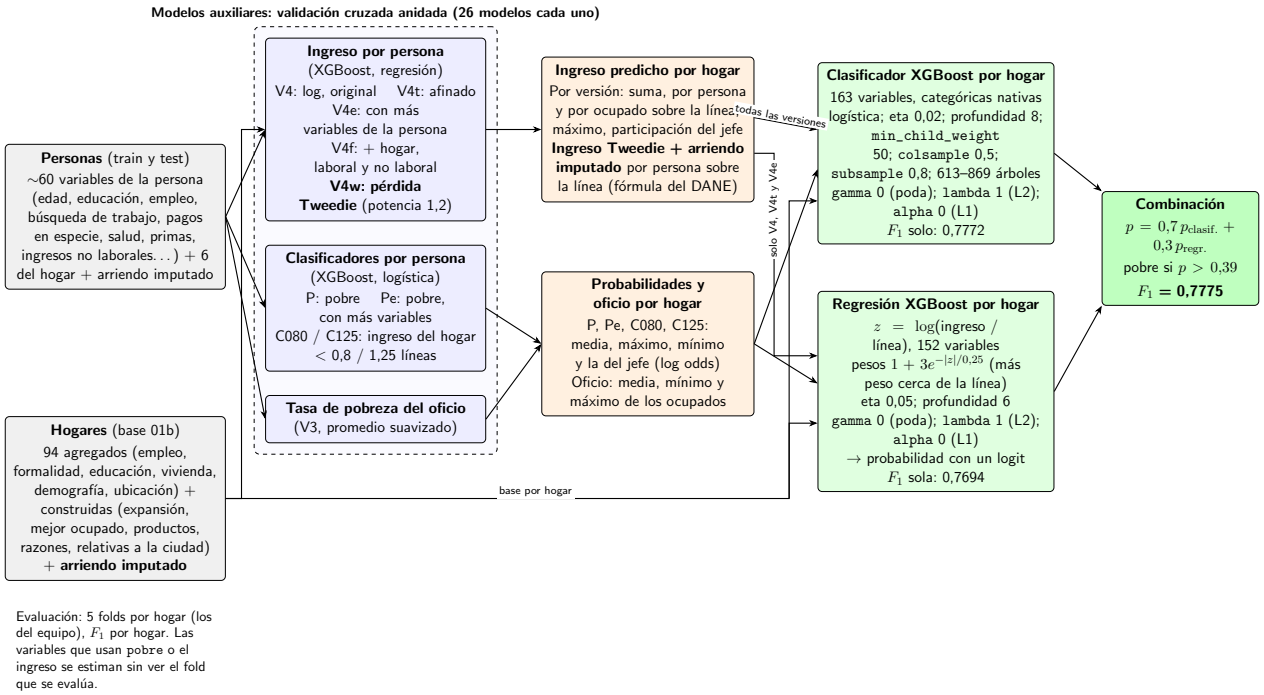


Figura 3: Estructura del modelo final. Los modelos auxiliares por persona predicen el ingreso y la pobreza de cada miembro (con validación cruzada anidada); sus predicciones se resumen por hogar y, junto con la base por hogar, alimentan un clasificador y una regresión XGBoost, cuyas probabilidades se combinan.

El modelo final tiene tres niveles (Figura 3). Primero, modelos XGBoost por persona predicen el ingreso de cada miembro del hogar (en cinco versiones, la mejor con pérdida Tweedie) y su probabilidad de ser pobre o de estar por debajo de 0,8 y 1,25 veces la línea; como usan el ingreso o `pobre`, se estiman con validación cruzada anidada. Segundo, esas predicciones se resumen por hogar, incluida la suma del ingreso predicho y el arriendo imputado por persona sobre la línea, que reproduce la definición de pobreza del DANE. Tercero, un clasificador XGBoost y una regresión XGBoost del ingreso, ambos por hogar, usan esos resúmenes junto con la base por hogar, y sus probabilidades se promedian (70/30) con un umbral de 0,39. La regresión usa solo las primeras versiones del ingreso predicho (V4, V4t y V4e, que concentran el 60 % de su ganancia): se armó antes de que existieran la versión afinada y la Tweedie, y con ellas combina igual.

4.6. Cómo replicarlos

Desde la raíz del repositorio:

1. `Rscript script/01_data_cleaning.r`: crea las bases limpias (`data/train_clean.rds`, `data/test_clean.rds` y `data/train_clean_augmented.rds`).

2. **Naive Bayes:** `Rscript script/03_naive_bayes.r`. La sección 4 hace el grid search de `laplace` y umbral, y la sección 5 guarda la submission con el nombre de los hiperparámetros elegidos.

3. **CART:** `Rscript script/04_carts.r`. La sección 4 estima `cv_arbol(x1, "up")`, que elige `cp` y umbral por validación cruzada; la sección 5 guarda la submission.

4. **XGBoost:** `Rscript script/05_xgboost.r`. La sección 4 estima `cv_xgb(x1)` (o `cv_xgb(x3)`, o con `base = "train_clean_augmented"`), que elige los hiperparámetros y el umbral por validación cruzada; la sección 5 guarda la submission.

5. **XGBoost por hogar:** primero `Rscript output/pruebas/hogar/01b_bases_hogar_main.r` (crea `data/train_hogar.rds` y `data/test_hogar.rds`) y después `Rscript script/05b_xgboost_hogar.r` (categóricas nativas por defecto). Cada prueba se guarda en `output/pruebas/xgb_hogar_nativo/`, así que volver a correrlo solo estima lo que falte; la sección 6 guarda las submissions. Para la combinación con el logit del equipo (sección 13), antes `Rscript output/pruebas/logit/06_logit_interacciones_main.r`.

6. **Comparación y equidad:** `Rscript script/06_comparacion_modelos.r` (después de 05b y del logit). Crea los Cuadros 14, 15 y 16 y la Figura 4. Las tablas de importancia por permutación las crea la sección 14 de 05b.

4.7. Importancia de las variables

La importancia de las variables del mejor modelo (XGBoost por hogar con Tweedie, combinado con la regresión del ingreso; F_1 0,778) se mide con pruebas de permutación (sección 14 de `05b_xgboost_hogar.r`). En cada fold se vuelven a estimar el clasificador y la regresión con los otros cuatro, con los mismos hiperparámetros y número de árboles (se verificó que reproducen exactamente las predicciones fuera de muestra), se permutan al azar los valores de una variable entre los hogares del fold de validación y se mide cuánto cae el F_1 con el umbral de la combinación (0,39). Esa caída es la importancia: lo que el modelo pierde cuando la variable deja de tener relación con la pobreza. Se promedia sobre los 5 folds y 3 permutaciones. A diferencia de la ganancia de los árboles, que mide cuánto se usa una variable al entrenar, la permutación mide cuánto depende de ella la predicción fuera de muestra.

Las variables muy correlacionadas se reemplazan entre sí: si se permuta una de las cinco versiones del ingreso predicho, las otras cuatro compensan, y cada una parece poco importante. Por eso el Cuadro 10 permuta también grupos completos de variables, con la misma permutación para todas sus columnas.

Cuadro 10: Importancia por permutación de grupos de variables en el mejor modelo (XGBoost con Tweedie y regresión, F_1 0,778): caída del F_1 al permutar a la vez todas las variables del grupo entre los hogares del fold de validación (promedio de 5 folds y 3 permutaciones; D.E.: desviación estándar). Ganancia: participación del grupo en la ganancia de los árboles del clasificador.

Grupo de variables	Variables	Caída del F_1	D.E.	Ganancia (%)
Ingreso predicho por persona (todas las versiones)	26	0,4232	0,0081	71,7
Probabilidad de ingreso menor a 0,8 y 1,25 líneas	8	0,0607	0,0154	6,5
Probabilidad de ser pobre por persona (stacking)	8	0,0437	0,0061	13,9
Base por hogar de 01b (sin ubicación)	89	0,0097	0,0024	4,0
Otras construidas (expansión, mejor ocupado, productos, razones)	24	0,0051	0,0014	2,8
Ubicación (dominio, departamento, zona, línea)	4	0,0022	0,0014	0,8
Tasa de pobreza del oficio	3	0,0005	0,0007	0,4

El ingreso predicho por persona es, de lejos, lo más importante: al permutarlo, el F_1 cae 0,42 (de 0,778 a 0,35). Le siguen las probabilidades de que el ingreso del hogar esté por debajo de 0,8 y 1,25 veces la línea (0,061) y la probabilidad de ser pobre por persona (0,044). Los 89 agregados de la base por hogar juntos solo restan 0,010, y la ubicación y la tasa de pobreza del oficio casi nada: su información ya está contenida en los modelos por persona, que los usan como variables. Las dos medidas coinciden en el orden general, pero la permutación le da más peso al ingreso predicho y a los cortes de ingreso que la ganancia.

Cuadro 11: Las 20 variables con mayor importancia por permutación en el mejor modelo (una variable a la vez; promedio de 5 folds y 3 permutaciones).

Variable	Código	Caída del F_1	D.E.	Ganancia (%)
Ingreso predicho + arriendo imputado, por persona sobre la línea (log; Tweedie)	`ing_arr_pc_lp_w`	0,0434	0,0047	42,8
Ingreso predicho por persona sobre la línea (log; con preguntas nuevas)	`log_ing_pred_pc_lp_e`	0,0227	0,0038	3,5
Ingreso predicho por persona sobre la línea (log; preguntas nuevas, afinado)	`log_ing_pred_pc_lp_f`	0,0060	0,0026	8,7
Probabilidad de ser pobre por persona, con preguntas nuevas (mínimo)	`pe_min`	0,0056	0,0027	6,5
Tenencia de la vivienda	`tenencia`	0,0039	0,0015	0,3
Probabilidad de ingreso menor a 1,25 líneas (promedio)	`pc125_media`	0,0031	0,0013	0,1
Probabilidad de ingreso menor a 0,8 líneas (mínimo)	`pc080_min`	0,0030	0,0015	3,0
Probabilidad de ser pobre por persona, con preguntas nuevas (del jefe)	`pe_jefe`	0,0023	0,0014	3,1
Probabilidad de ingreso menor a 1,25 líneas (del jefe)	`pc125_jefe`	0,0020	0,0011	0,3
Probabilidad de ser pobre por persona, con preguntas nuevas (promedio)	`pe_media`	0,0019	0,0015	0,7
Ingreso predicho por ocupado sobre la línea (con preguntas nuevas)	`ing_pred_por_ocup_e`	0,0018	0,0007	0,2
Cuartos por persona	`cuartos_pc`	0,0016	0,0010	0,2
Participación del jefe en el ingreso predicho (con preguntas nuevas)	`prop_ing_jefe_e`	0,0016	0,0007	0,1
Ingreso predicho por persona sobre la línea (log; afinado)	`log_ing_pred_pc_lp_t`	0,0014	0,0009	0,5
Ingreso predicho por persona sobre la línea (log; Tweedie)	`log_ing_pred_pc_lp_w`	0,0014	0,0005	12,4
Probabilidad de ingreso menor a 1,25 líneas (mínimo)	`pc125_min`	0,0014	0,0012	0,5
Ciudad (dominio geográfico)	`dominio`	0,0014	0,0008	0,2
Primas, subsidios y bonificaciones por persona	`beneficios_pc`	0,0012	0,0009	0,2
Mayor ingreso predicho de un miembro sobre la línea (Tweedie)	`max_ing_pred_lp_w`	0,0012	0,0010	0,3
Educación máxima de los adultos × ocupados por persona	`educ_adultos_x_ocup_pc`	0,0012	0,0008	0,2

Una por una (Cuadro 11), la variable más importante es `ing_arr_pc_lp_w`: el ingreso Tweedie predicho del hogar más el arriendo imputado, por persona y relativo a la línea, que reproduce la definición de pobreza del DANE con el ingreso de las personas predicho. Permutarla resta 0,043 al F_1 aunque las demás versiones del ingreso sigan en el modelo. La siguen el ingreso predicho con las preguntas que antes no se usaban (versiones e y f),

el mínimo de la probabilidad de ser pobre entre los miembros del hogar y la tenencia de la vivienda. De las 163 variables, 21 tienen una importancia nula o negativa: el modelo no perdería nada sin ellas.

Cuadro 12: Las 15 variables más importantes que no salen de un modelo (base por hogar, construidas y ubicación), con importancia por permutación en el mejor modelo.

Variable	Código	Caída del F_1	D.E.	Ganancia (%)
Tenencia de la vivienda	`tenencia`	0,0039	0,0015	0,3
Cuartos por persona	`cuartos_pc`	0,0016	0,0010	0,2
Ciudad (dominio geográfico)	`dominio`	0,0014	0,0008	0,2
Primas, subsidios y bonificaciones por persona	`beneficios_pc`	0,0012	0,0009	0,2
Educación máxima de los adultos × ocupados por persona	`educ_adultos_x_ocup_pc`	0,0012	0,0008	0,2
Arriendo por persona relativo a la mediana de la ciudad	`rel_dom_log_arriendo`	0,0010	0,0010	0,2
Oficio del jefe	`jefe_oficio`	0,0010	0,0007	0,2
Arriendo (pagado o estimado) por persona sobre la línea (log)	`log_arriendo_pc_lp`	0,0010	0,0008	0,2
Coeficiente de variación de la educación de los adultos	`cv_educ_adultos`	0,0009	0,0007	0,3
Arriendo por persona sobre la línea × línea (log)	`arriendo_x_log_lp`	0,0009	0,0005	0,2
Departamento	`depto`	0,0009	0,0009	0,3
Educación de los ocupados por persona × formales por persona	`educ_ocup_x_formal_pc`	0,0007	0,0009	0,0
Años de educación de los ocupados por persona	`educ_ocup_suma_pc`	0,0006	0,0004	0,1
Proporción en régimen contributivo de salud	`prop_contributivo`	0,0006	0,0005	0,1
Edad del jefe	`jefe_edad`	0,0006	0,0006	0,2

Entre las variables que no salen de un modelo (Cuadro 12), las que más aportan describen la vivienda y el empleo del hogar: la tenencia de la vivienda (que define si el hogar recibe arriendo imputado), los cuartos por persona, la ciudad, las primas, subsidios y bonificaciones de los miembros, la educación de los adultos combinada con cuántos trabajan, el arriendo relativo al de su ciudad y el oficio del jefe. Todas aportan poco por separado (menos de 0,004 de F_1) porque su información ya entra en los modelos por persona, que las usan como variables: el ingreso predicho resume el empleo, la educación y la vivienda de cada miembro.

Esas permutaciones subestiman la importancia de las variables de base: cuando se permuta, por ejemplo, la formalidad del hogar, los modelos auxiliares siguen viendo la formalidad de cada persona y sus predicciones no cambian. Para medir cuánto importa cada concepto en todo el modelo, la sección 15 de `05b_xgboost_hogar.r` permuta sus variables a la vez en las personas (la entrada de los modelos auxiliares) y en el hogar, vuelve a calcular el ingreso predicho, las probabilidades por persona y la tasa del oficio con los modelos de cada fold, y después la predicción final (Cuadro 13). También separa la importancia directa (solo las variables del hogar) de la que pasa por los modelos auxiliares (solo las de las personas).

Cuadro 13: Importancia de extremo a extremo por concepto en el mejor modelo: caída del F_1 al permutar las variables del concepto. Total: en las personas (entrada de los modelos auxiliares) y en el hogar; directa: solo en el hogar; vía modelos auxiliares: solo en las personas. La perturbación pasa por toda la cadena de modelos (promedio de 5 folds).

Concepto	Variables (persona / hogar)	Total	Directa	Vía modelos auxiliares	D.E. total
Formalidad, posición y oficio	4 / 32	0,226	0,002	0,226	0,004
Ingresos no laborales	10 / 10	0,143	0,001	0,137	0,008
Vivienda y arriendo	3 / 10	0,118	0,037	0,045	0,005
Ocupación y horas de trabajo	9 / 26	0,117	0,005	0,122	0,006
Búsqueda de trabajo e ingresos de desocupados	10 / 1	0,070	0,000	0,070	0,007
Edad, sexo y tamaño del hogar	4 / 14	0,050	0,035	0,023	0,005
Ubicación y línea de pobreza	4 / 8	0,024	0,009	0,017	0,002
Educación	3 / 19	0,021	0,006	0,024	0,003
Primas, subsidios y pagos en especie	16 / 4	0,012	0,005	0,008	0,001
Salud	2 / 5	0,009	0,001	0,010	0,001

Visto así, las variables que más importan son las del trabajo: la formalidad, la posición ocupacional y el oficio (el F_1 cae 0,23), los ingresos no laborales (0,14), la ocupación y las horas trabajadas (0,12) y la búsqueda de trabajo e ingresos de los desocupados (0,07); además, la vivienda y el arriendo (0,12). Casi todo su efecto pasa por los modelos auxiliares: su importancia directa es de 0,005 o menos, salvo en la vivienda (0,037), que entra directamente en la variable de ingreso más arriendo imputado, y en el tamaño del hogar (0,035), que convierte el ingreso en ingreso por persona. La educación (0,021) y la salud (0,009) importan menos de lo esperado porque su información se repite en los conceptos del trabajo: al permutar la educación, el modelo la recupera de la posición ocupacional, el oficio y la formalidad. Las importancias no se suman entre conceptos ni entre la parte directa y la que pasa por los modelos, porque los conceptos están correlacionados y los efectos interactúan.

5. Comparación de modelos y equidad

`06_comparacion_modelos.r` compara el mejor modelo de cada categoría con la misma evaluación: los 5 folds por hogar de 05b y el F_1 por hogar. Naive Bayes, CART y XGBoost por persona se volvieron a estimar con esos folds y su mejor configuración (en sus scripts usaron 10 folds); el F_1 casi no cambia (Cuadro 14). Las categorías se ordenan solas por información usada: los modelos por persona (0,67–0,71), el logit y el XGBoost con solo la base por hogar (0,745–0,753), y los modelos por hogar con las variables de la validación cruzada anidada (0,774–0,778).

Cuadro 14: Mejor modelo de cada categoría con la misma evaluación: 5 folds por hogar y F_1 por hogar. Naive Bayes, CART y XGBoost por persona se reestimaron con estos folds (en sus scripts usaron 10).

Categoría	Modelo	F_1 en su script	F_1 (5 folds)	F_1 honesto	Umbral
CART	Por persona, x1, cp 2,5e-05, up-sampling	0,670	0,6685	0,6679	0,62
Naive Bayes	Por persona, 16 variables (x1), laplace 0	0,675	0,6755	0,6752	0,42
XGBoost por persona	24 variables (x3), 500 rondas	0,706	0,7055	0,7055	0,32
Logit lasso	Por hogar, 1.159 columnas con interacciones (main)	0,745	0,7451	0,7449	0,37
XGBoost por hogar	Solo la base por hogar de 01b		0,7534	0,7532	0,36
XGBoost por hogar	Mejor sin Tweedie, con la regresión del ingreso		0,7738	0,7736	0,38
Random forest	Por hogar, variables del mejor XGBoost		0,7752	0,7750	0,40
XGBoost por hogar	Mejor: Tweedie, con la regresión del ingreso		0,7775	0,7775	0,39

Para saber si los modelos generan desigualdades, el script calcula, con las predicciones fuera de muestra de train, el desempeño de cada modelo por grupo de población. En la focalización de un programa, un falso negativo es un hogar pobre excluido (error de exclusión) y un falso positivo, un hogar no pobre incluido (error de inclusión). Se reportan la sensibilidad (% de los hogares pobres que el modelo detecta) y la tasa de falsos positivos (% de los no pobres que predice pobres).

Cuadro 15: Mejor modelo (XGBoost por hogar con Tweedie y regresión): desempeño por grupo de población, con las predicciones fuera de muestra de train. Sensibilidad: % de los hogares pobres detectados; falsos positivos: % de los no pobres predichos pobres; precisión: % de los predichos pobres que sí lo son.

Atributo	Grupo	Hogares	% pobres	% predicho	Sensibilidad	Falsos pos.	Precisión	F_1
Sexo del jefe	Hombre	95.959	18,3	19,5	78,9	6,2	74,0	0,764
	Mujer	68.999	22,4	24,3	82,7	7,4	76,2	0,793
Empleo del jefe	Formal (cotiza a pensión)	45.812	5,6	5,3	65,1	1,7	69,8	0,674
	Informal	71.343	26,1	28,4	80,2	10,1	73,8	0,769
	No ocupado	47.803	24,7	26,8	84,8	7,8	78,0	0,813
Zona	Cabecera	149.486	19,0	20,3	80,8	6,2	75,4	0,780
	Resto (rural)	15.472	30,0	32,9	80,0	12,6	73,1	0,764
Edad del jefe	Menos de 30	20.232	24,0	26,0	82,3	8,2	76,0	0,790
	30 a 44	46.819	24,6	27,1	84,1	8,4	76,5	0,801
	45 a 64	65.460	17,5	18,3	77,3	5,9	73,6	0,754
	65 o más	32.447	16,0	17,1	78,9	5,3	73,9	0,763
Educación del jefe	Primaria o menos	55.317	28,8	31,7	83,4	10,8	75,8	0,794
	Secundaria o media	65.227	21,3	22,9	81,1	7,2	75,3	0,781
	Superior	44.414	7,3	6,9	65,4	2,3	69,6	0,674
Tamaño del hogar	1 o 2 personas	60.278	10,7	10,5	66,5	3,8	67,9	0,672
	3 o 4 personas	71.505	20,5	22,4	80,3	7,5	73,5	0,767
	5 o más	33.175	35,8	39,6	88,8	12,1	80,4	0,844
Menores	Con menores de 18	86.722	29,6	32,9	85,1	10,9	76,7	0,807
	Sin menores de 18	78.236	9,3	8,9	65,2	3,1	68,3	0,667
Vivienda	Propia	67.901	14,2	15,0	78,2	4,6	73,8	0,759
	Arriendo	64.452	22,4	24,1	79,9	8,0	74,2	0,769
	Usufructo u otra	32.605	27,4	29,8	84,5	9,1	77,7	0,810

El Cuadro 15 muestra el patrón del mejor modelo. Los pobres de los grupos con poca pobreza se detectan menos: en los hogares con jefe formal (que cotiza a pensión), con jefe

con educación superior, de una o dos personas o sin menores, la sensibilidad es de 65–67 %, frente a 80–89 % en los demás, y el modelo subestima su pobreza. Un hogar pobre con jefe formal o educado se parece a los no pobres, así que el modelo lo excluye con más frecuencia. En los grupos con mucha pobreza ocurre lo contrario: más errores de inclusión. En la zona rural la sensibilidad es la misma que en las cabeceras (80 %), pero la tasa de falsos positivos es el doble (12,6 % frente a 6,2 %); lo mismo con jefe informal, con primaria o menos y en hogares de cinco o más personas. Por sexo del jefe la diferencia es pequeña y a favor de los hogares con jefa: se detecta el 82,7 % de los pobres, frente a 78,9 % con jefe hombre, con algo más de falsos positivos (7,4 % frente a 6,2 %).

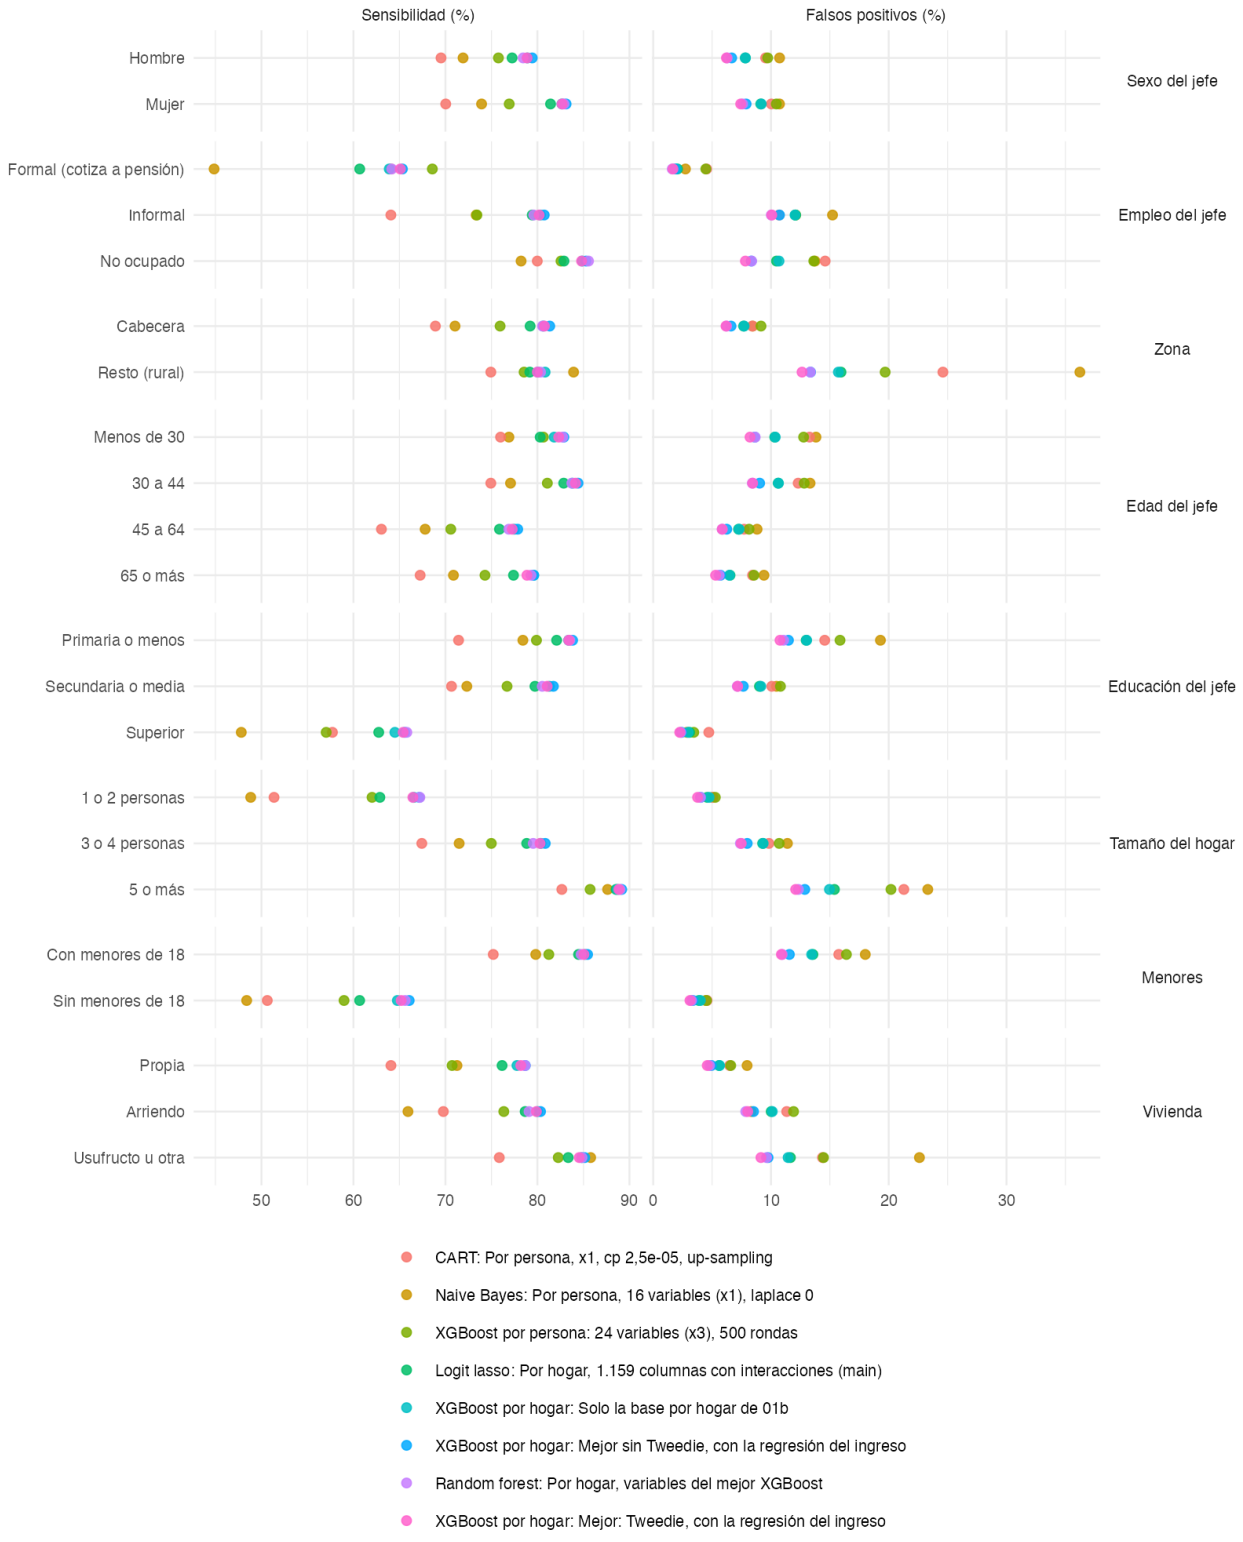


Figura 4: Sensibilidad y tasa de falsos positivos por grupo de población, para el mejor modelo de cada categoría (predicciones fuera de muestra de train).

Cuadro 16: Brecha de sensibilidad por atributo: diferencia, en puntos porcentuales, entre el grupo con mayor y menor % de hogares pobres detectados (entre paréntesis, el grupo con menor sensibilidad).

Modelo	Sexo del jefe	Empleo del jefe	Zona	Edad del jefe	Educación del jefe	Tamaño del hogar	Menores	Vivienda
CART: Por persona, x1, cp 2,5e-05, up-sampling	0,5 (Hombre)	15,9 (Informal)	6,0 (Cabecera)	13,0 (45 a 64)	13,7 (Superior)	31,3 (1 o 2 personas)	24,6 (Sin menores de 18)	11,8 (Propia)
Naive Bayes: Por persona, 16 variables (x1), laplace 0	2,0 (Hombre)	33,4 (Formal (cotiza a pensión))	12,9 (Cabecera)	9,3 (45 a 64)	30,6 (Superior)	38,8 (1 o 2 personas)	31,4 (Sin menores de 18)	19,9 (Arriendo)
XGBoost por persona: 24 variables (x3), 500 rondas	1,2 (Hombre)	14,0 (Formal (cotiza a pensión))	2,6 (Cabecera)	10,5 (45 a 64)	22,9 (Superior)	23,7 (1 o 2 personas)	22,3 (Sin menores de 18)	11,5 (Propia)
Logit lasso: Por hogar, 1.159 columnas con interacciones (main)	4,2 (Hombre)	22,2 (Formal (cotiza a pensión))	0,0 (Resto (rural))	7,0 (45 a 64)	19,3 (Superior)	25,7 (1 o 2 personas)	23,8 (Sin menores de 18)	7,2 (Propia)
XGBoost por hogar: Solo la base por hogar de 01b	3,8 (Hombre)	21,0 (Formal (cotiza a pensión))	0,2 (Cabecera)	6,3 (45 a 64)	18,9 (Superior)	22,1 (1 o 2 personas)	20,4 (Sin menores de 18)	7,0 (Propia)
XGBoost por hogar: Mejor sin Tweedie, con la regresión del ingreso	3,7 (Hombre)	20,0 (Formal (cotiza a pensión))	1,3 (Resto (rural))	6,6 (45 a 64)	18,2 (Superior)	22,0 (1 o 2 personas)	19,4 (Sin menores de 18)	6,5 (Propia)
Random forest: Por hogar, variables del mejor XGBoost	4,4 (Hombre)	21,4 (Formal (cotiza a pensión))	0,2 (Resto (rural))	6,9 (45 a 64)	17,7 (Superior)	21,8 (1 o 2 personas)	19,1 (Sin menores de 18)	6,2 (Propia)
XGBoost por hogar: Mejor: Tweedie, con la regresión del ingreso	3,8 (Hombre)	19,7 (Formal (cotiza a pensión))	0,8 (Resto (rural))	6,9 (45 a 64)	18,0 (Superior)	22,4 (1 o 2 personas)	19,9 (Sin menores de 18)	6,4 (Propia)

Este es el patrón esperable cuando los grupos tienen tasas de pobreza muy distintas: con una sola regla de decisión no se pueden igualar a la vez la sensibilidad y la tasa de falsos positivos entre grupos. La Figura 4 y el Cuadro 16 muestran que los modelos más precisos reducen casi todas las brechas: la brecha de falsos positivos entre zonas pasa de 27,8 puntos con naive Bayes a 6,5 con el mejor modelo, y la de sensibilidad según el empleo del jefe, de 33,4 a 19,7. La excepción es el sexo del jefe: con los modelos por persona la brecha era de 1–2 puntos y con los modelos por hogar es de unos 4, siempre a favor de los hogares con jefa. Si el modelo se usara para focalizar, la brecha más relevante es la de los hogares pobres pequeños o con jefe formal o educado, que serían excluidos con más frecuencia; se podría corregir con umbrales por grupo, a costa de más errores de inclusión.

6. Decisiones metodológicas

Datos (`01_data_cleaning.r`).

- Variable objetivo: `pobre` = ingreso per cápita de la unidad de gasto con arriendo imputado (`Ingpcug`) < línea de pobreza; se verificó en el 100 % de los hogares. Las variables que solo están en train (ingresos, `Indigente`, `Npobres`...) no se usan como predictores.
- Lectura con `guess_max = Inf` (sin ella se pierden columnas vacías en las primeras filas) y unión de personas y hogares por sus columnas comunes, una a muchas.
- Preguntas sí/no a 1/0; `NA` significa "no aplica" por los saltos del cuestionario y no se reemplaza por 0 sin revisarlo (excepción: `ocupado`). Montos 98/99 (no sabe / no informa) a `NA`; los valores atípicos se conservan.
- Categóricas con sus códigos del DANE y, además, dummies por categoría. Años de educación aprobados construidos con el nivel y el grado, e imputados con el promedio del nivel.
- Se eliminan de train dos hogares con número de cuartos imposible; de test nunca se elimina nada.
- Variables nuevas del hogar: proporciones de ocupados, mujeres y dependientes, tasa de dependencia, educación de los adultos, coeficientes de variación, hacinamiento, arriendo per cápita sobre la línea y arriendo imputado (regla del DANE reconstruida en el 98,4 % de los hogares).

- Bases alternativas: aumentada (hogares pobres replicados hasta balancear) y sin el 10 % más rico en el entrenamiento (la validación siempre con todos). Ninguna mejoró.

Evaluación.

- F_1 por hogar, con folds por hogar (todos los miembros en el mismo fold) y el umbral escogido por validación cruzada; desde 05b, los mismos 5 folds del equipo, para comparar.
- La probabilidad del hogar en los modelos por persona es el promedio de los log odds de sus miembros (mejor que promediar probabilidades).
- F_1 honesto (umbral escogido con los otros folds) y otras particiones en folds para medir el ruido: diferencias de menos de 0,001 son ruido. El puntaje público de Kaggle (20 % de test) tiene una desviación estándar de 0,006, así que los modelos se escogen por la validación cruzada.

Modelos por persona (03–05).

- Naive Bayes: variables que no repitan información (cuenta dos veces la correlacionada) y logaritmos para las asimétricas; `laplace` casi no importa; sus probabilidades están descalibradas, por eso el umbral es alto.
- CART con caret: función de evaluación propia (F_1 por hogar), grilla de `cp` y up-sampling solo dentro de cada fold.
- XGBoost con un modelo propio para caret (el de caret no funciona con xgboost 3), folds en paralelo y semilla fija.

XGBoost por hogar (05b).

- Una fila por hogar, con la base de agregados del equipo: el mayor salto de todo el trabajo (0,706 a 0,753).
- Variables que usan `pobre` o el ingreso (tasa de pobreza del oficio, ingreso predicho por persona, probabilidad por persona) con validación cruzada anidada, para que el fold evaluado nunca use su propia etiqueta.
- Categóricas nativas de XGBoost, no códigos enteros ni one-hot. Parada temprana; `eta` 0,02; hiperparámetros con superficie plana.
- Lo que más aportó: el stacking con el modelo por persona, el ingreso predicho, 16 preguntas que ningún modelo usaba (pagos en especie, búsqueda de trabajo, ingresos de desocupados e inactivos) y la pérdida Tweedie en el modelo del ingreso.
- Lo que no aportó: base aumentada o sin ricos, combinaciones no lineales, logaritmos, normalización, índices, indigencia, pesos cerca de la línea, modelo especialista, naive Bayes, random forest y el logit en la combinación.

- Submission final: combinación del mejor XGBoost con la regresión del ingreso (70/30), la de mayor F_1 honesto.