Predicting Poverty: análisis descriptivo y modelos

Maria Jose Perez, Juan Manuel Lozano, Samuel Suárez Valle

21 de octubre de 2026

1. Datos

Se usa la muestra de entrenamiento de la GEIH 2018 (DANE): 543.103 personas en 164.958 hogares. Un hogar es pobre cuando su ingreso per cápita de la unidad de gasto (con arriendo imputado) es menor que la línea de pobreza de su dominio. El 20,0 % de los hogares y el 25,1 % de las personas son pobres.

2. Estadísticas descriptivas

El Cuadro 1 compara las medias de las características de las personas pobres y no pobres. La diferencia es la media de los pobres menos la de los no pobres, y el p-valor viene de una prueba t de diferencia de medias. Las variables de educación y de tenencia de vivienda son dummies por categoría, así que su media es la proporción de personas en esa categoría.

3. Visualización

Las figuras relacionan el ingreso per cápita con cada variable. La línea roja punteada es la mediana de la línea de pobreza ($280.072); la línea varía por dominio, por lo que se usa la mediana como referencia.

Cuadro 1: Estadísticas descriptivas por condición de pobreza

Variable	No pobres	Pobres	Diferencia	p-valor
mujer	0.525	0.541	0.016	0.000
afiliado_salud	0.941	0.906	-0.035	0.000
ocupado	0.508	0.304	-0.204	0.000
educ_ninguno	0.041	0.093	0.052	0.000
educ_preescolar	0.026	0.040	0.014	0.000
educ_primaria	0.232	0.343	0.111	0.000
educ_secundaria	0.166	0.230	0.064	0.000
educ_media	0.240	0.202	-0.039	0.000
educ_superior	0.295	0.092	-0.203	0.000
educ_no_sabe	0.000	0.000	0.000	0.289
vivienda_propia_pagada	0.427	0.294	-0.133	0.000
vivienda_propia_pagando	0.041	0.016	-0.025	0.000
vivienda_arriendo	0.353	0.414	0.061	0.000
vivienda_usufructo	0.145	0.159	0.014	0.000
vivienda_sin_titulo	0.032	0.115	0.082	0.000
vivienda_otra	0.001	0.001	0.001	0.000
Estrato1	3.122	2.126	-0.996	0.000
tamano_empresa	2.152	0.642	-1.510	0.000
anos	35.651	27.303	-8.347	0.000
meses_empresa	43.769	25.511	-18.258	0.000
horas_trabajo_semana	45.421	41.735	-3.687	0.000
cuartos_hogar	3.724	3.212	-0.512	0.000
cuartos_dormir	2.341	2.203	-0.138	0.000
arriendo_estimado	599617.307	277717.379	-321899.928	0.000
prop_edad_trabajar	0.856	0.731	-0.125	0.000

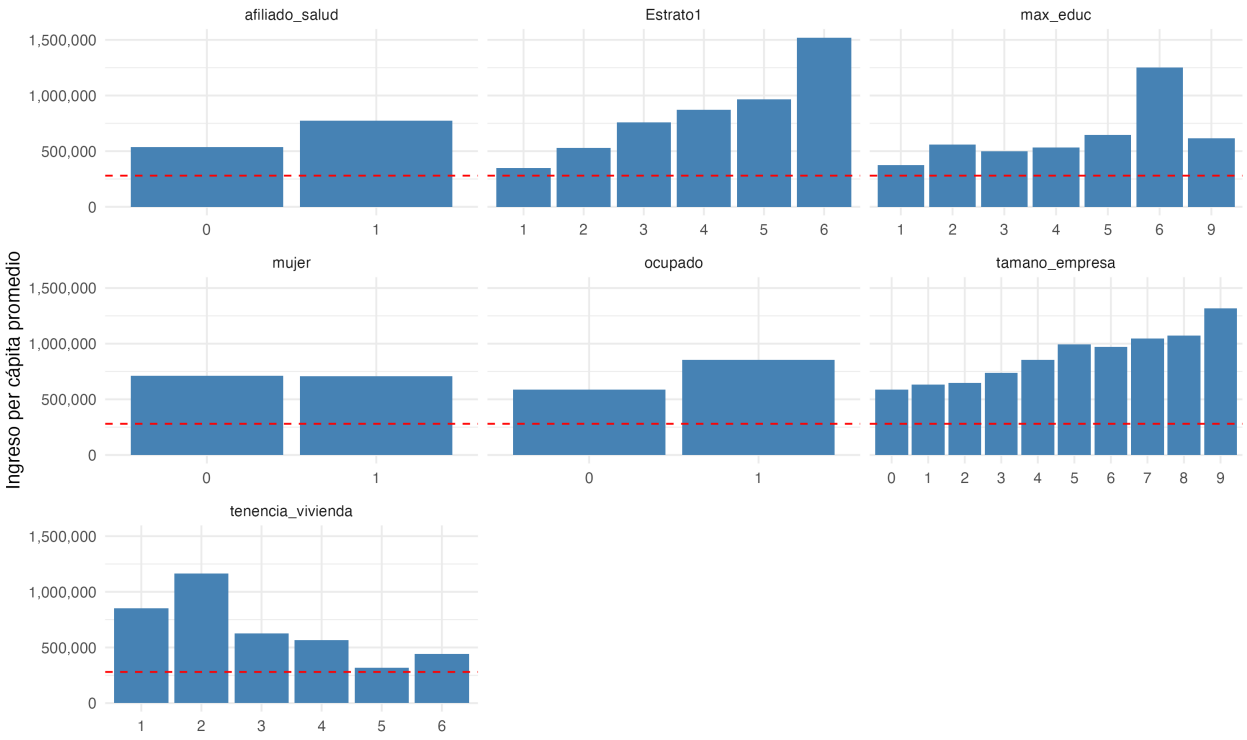


Figura 1: Ingreso per cápita promedio por categoría de las variables dummies y categóricas.

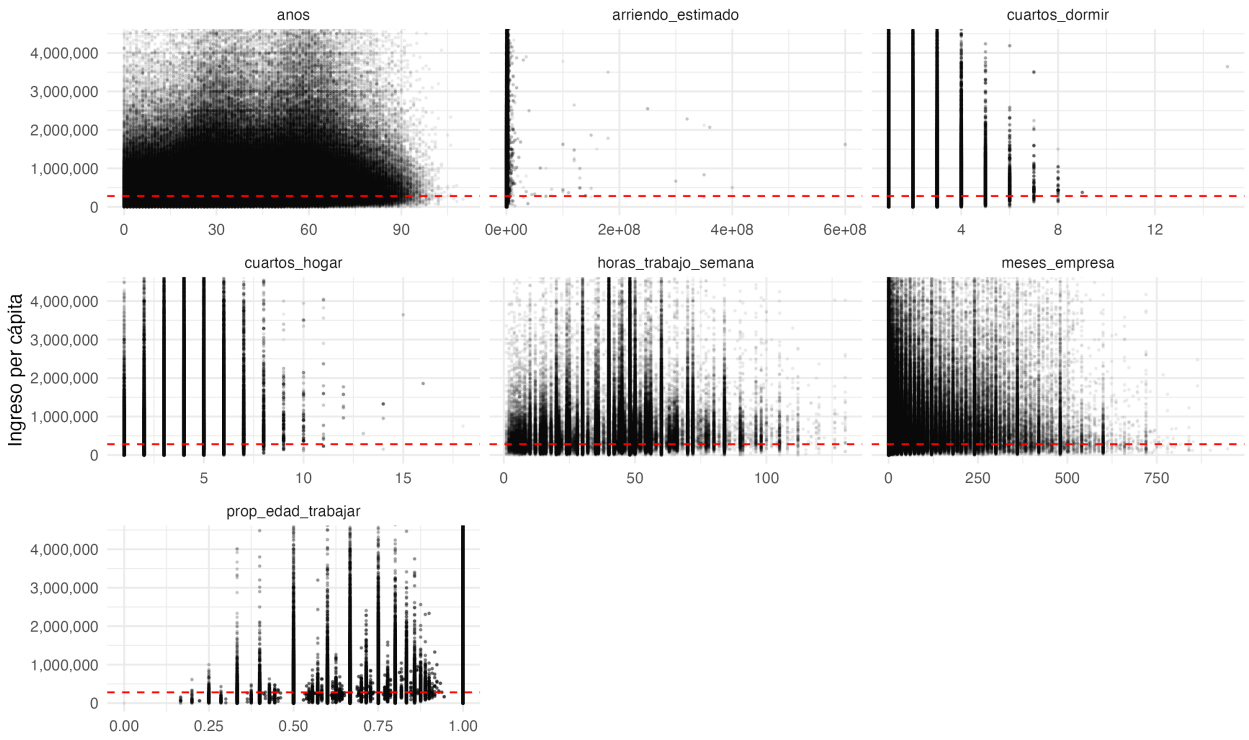


Figura 2: Ingreso per cápita frente a las variables continuas. El eje y se corta en el percentil 99 del ingreso ($4.400.000).

4. Modelos

4.1. Evaluación

Todos los modelos se evalúan igual, así que sus F_1 son comparables:

- **Validación cruzada por hogar:** 10 folds construidos sobre los hogares (`set.seed(123)`), de modo que todas las personas de un hogar quedan en el mismo fold.
- **Predicción por hogar:** el modelo predice la probabilidad de cada persona; la probabilidad del hogar es el promedio de los log odds, $\log(p/(1-p))$, de sus miembros. El hogar se clasifica como pobre si esa probabilidad supera el umbral.
- **Métrica:** F_1 sobre los hogares del fold de validación, promediado entre los 10 folds. El umbral se elige en la misma validación cruzada, por lo que el F_1 reportado es levemente optimista.

4.2. Mejores modelos

Los dos mejores modelos usan las mismas 16 variables: `anos`, `anos_educ_imp`, `mujer`, `ocupado`, `afiliado_salud`, `regimen_salud`, `actividad_sem_pasada`, `log_meses_empresa`,

tamano_empresa, posicion_ocupacional, horas_trabajo_semana, arriendo_pc_sobre_lp, prop_ocupados_hogar, tenencia_vivienda, recibio_arriendos_pensiones y ayudas_instituciones. Las categóricas con códigos del DANE y las dummies entran como factores.

Cuadro 2: Mejores modelos por validación cruzada.

Modelo	Script	Hiperparámetros	Umbral	F_1
Naive Bayes	03_naive_bayes.r	laplace = 0	0,42	0,675
CART	04_carts.r	cp = 0,000025; gini; up-sampling dentro de cada fold	0,61	0,670

Las predicciones de test están en output/submissions/: NB_laplace_0_threshold_042.csv (naive Bayes) y CART_up_cp_0000025_threshold_061.csv (CART). Las dos se regeneran al correr cada script.

4.3. Cómo replicarlos

Desde la raíz del repositorio:

1. Rscript script/01_data_cleaning.r: crea las bases limpias (data/train_clean.rds, data/test_clean.rds y data/train_clean_augmented.rds).
2. **Naive Bayes:** Rscript script/03_naive_bayes.r. La sección 4 hace el grid search de laplace y umbral, y la sección 5 guarda la submission con el nombre de los hiperparámetros elegidos.
3. **CART:** Rscript script/04_carts.r. La sección 4 estima cv_arbol(x1, "up"), que elige cp y umbral por validación cruzada; la sección 5 guarda la submission.

4.4. Importancia de las variables

Para medir qué variables son más relevantes se estimó un CART con todas las variables disponibles (una versión por concepto), 66 interacciones entre las numéricas centrales y algunas razones (146 columnas), con la base aumentada y un grid search de cp, minbucket, criterio de partición, maxdepth, maxsurrogate y umbral (código en output/pruebas/todas/). El mejor modelo (minbucket = 100, entropía, maxdepth = 15, 5 cortes sustitutos, umbral 0,70) tiene un F_1 de 0,670, igual al CART con 16 variables. Un CART solo con las seis variables y las tres interacciones más importantes del Cuadro 3, con la misma grilla, llega a un F_1 de 0,641 (código en output/pruebas/top9/): las demás variables sí aportan.

El Cuadro 3 muestra la importancia por reducción de la impureza, normalizada para que sume 100. La importancia de cada interacción se reparte por partes iguales entre las variables que la forman. La columna "rpart" suma los cortes principales y los sustitutos; "cortes principales" cuenta solo los cortes que el árbol usa.

Cuadro 3: Importancia de las variables (reducción de impureza, suma 100).

Variable	rpart	Cortes principales
prop_ocupados_hogar	29,5	21,6
arriendo_pc_sobre_lp	17,5	15,6
educ_max_adultos	10,6	21,4
linea_pobreza	9,8	8,7
cuartos_dormir	5,6	0,4
regimen_salud	4,5	15,2
anos_educ_imp	3,9	0,2
prop_dependientes	3,5	0,3
personas_hogar	3,3	0,6
anos	2,0	0,9
tenencia_vivienda	1,6	5,3

La interacción más importante es educación máxima de los adultos por proporción de ocupados del hogar: concentra el 40 % de la reducción de impureza en los cortes principales. Las interacciones y razones suman el 70 % de la importancia (rpart).