Predicting Poverty: análisis descriptivo y modelos

Maria Jose Perez, Juan Manuel Lozano, Samuel Suárez Valle

24 de octubre de 2026

1. Datos

Se usa la muestra de entrenamiento de la GEIH 2018 (DANE): 543.103 personas en 164.958 hogares. Un hogar es pobre cuando su ingreso per cápita de la unidad de gasto (con arriendo imputado) es menor que la línea de pobreza de su dominio. El 20,0 % de los hogares y el 25,1 % de las personas son pobres.

2. Estadísticas descriptivas

El Cuadro 1 compara las medias de las características de las personas pobres y no pobres. La diferencia es la media de los pobres menos la de los no pobres, y el p-valor viene de una prueba t de diferencia de medias. Las variables de educación y de tenencia de vivienda son dummies por categoría, así que su media es la proporción de personas en esa categoría.

3. Visualización

Las figuras relacionan el ingreso per cápita con cada variable. La línea roja punteada es la mediana de la línea de pobreza ($280.072); la línea varía por dominio, por lo que se usa la mediana como referencia.

Cuadro 1: Estadísticas descriptivas por condición de pobreza

Variable	No pobres	Pobres	Diferencia	p-valor
mujer	0.525	0.541	0.016	0.000
afiliado_salud	0.941	0.906	-0.035	0.000
ocupado	0.508	0.304	-0.204	0.000
educ_ninguno	0.041	0.093	0.052	0.000
educ_preescolar	0.026	0.040	0.014	0.000
educ_primaria	0.232	0.343	0.111	0.000
educ_secundaria	0.166	0.230	0.064	0.000
educ_media	0.240	0.202	-0.039	0.000
educ_superior	0.295	0.092	-0.203	0.000
educ_no_sabe	0.000	0.000	0.000	0.289
vivienda_propia_pagada	0.427	0.294	-0.133	0.000
vivienda_propia_pagando	0.041	0.016	-0.025	0.000
vivienda_arriendo	0.353	0.414	0.061	0.000
vivienda_usufructo	0.145	0.159	0.014	0.000
vivienda_sin_titulo	0.032	0.115	0.082	0.000
vivienda_otra	0.001	0.001	0.001	0.000
Estrato1	3.122	2.126	-0.996	0.000
tamano_empresa	2.152	0.642	-1.510	0.000
anos	35.651	27.303	-8.347	0.000
meses_empresa	43.769	25.511	-18.258	0.000
horas_trabajo_semana	45.421	41.735	-3.687	0.000
cuartos_hogar	3.724	3.212	-0.512	0.000
cuartos_dormir	2.341	2.203	-0.138	0.000
arriendo_estimado	599617.307	277717.379	-321899.928	0.000
prop_edad_trabajar	0.856	0.731	-0.125	0.000

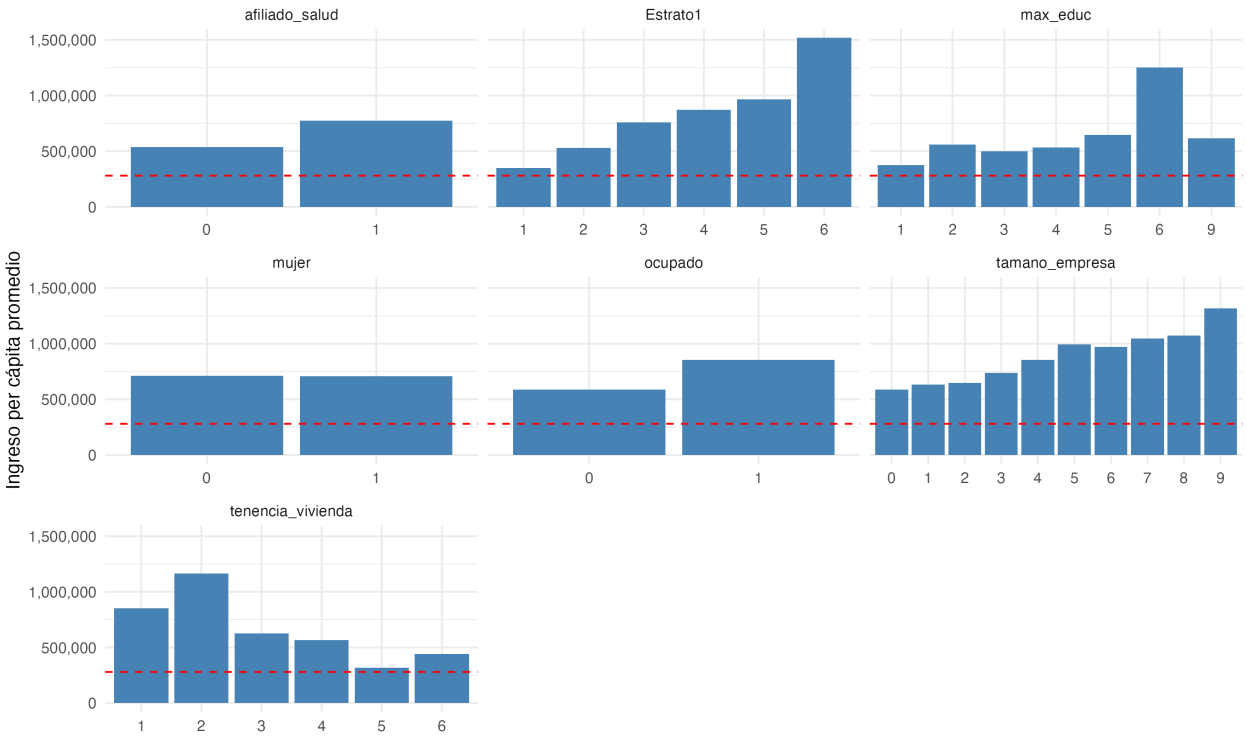


Figura 1: Ingreso per cápita promedio por categoría de las variables dummies y categóricas.

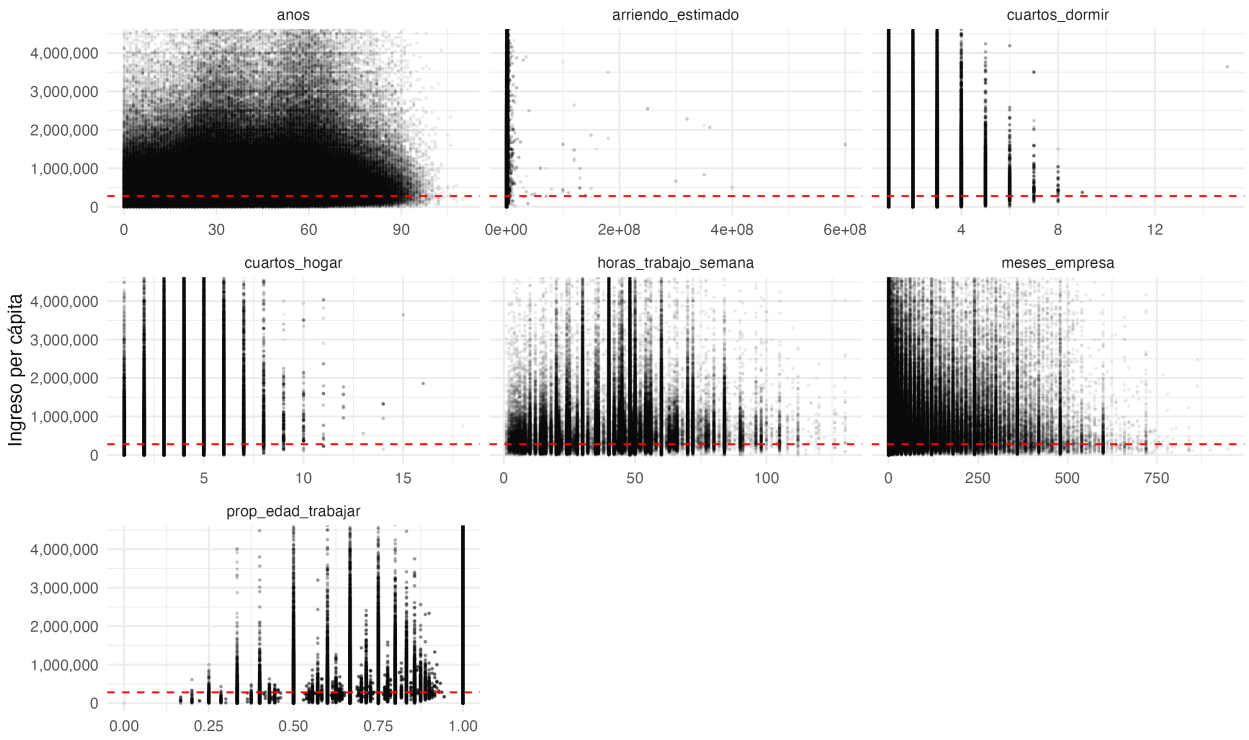


Figura 2: Ingreso per cápita frente a las variables continuas. El eje y se corta en el percentil 99 del ingreso ($4.400.000).

4. Modelos

4.1. Evaluación

Todos los modelos se evalúan igual, así que sus F_1 son comparables:

- **Validación cruzada por hogar:** 10 folds construidos sobre los hogares (`set.seed(123)`), de modo que todas las personas de un hogar quedan en el mismo fold.
- **Predicción por hogar:** el modelo predice la probabilidad de cada persona; la probabilidad del hogar es el promedio de los log odds, $\log(p/(1-p))$, de sus miembros. El hogar se clasifica como pobre si esa probabilidad supera el umbral.
- **Métrica:** F_1 sobre los hogares del fold de validación, promediado entre los 10 folds. El umbral se elige en la misma validación cruzada, por lo que el F_1 reportado es levemente optimista.

4.2. Mejores modelos

Naive Bayes, CART y XGBoost con `x1` usan las mismas 16 variables: `anos`, `anos_educ_imp`, `mujer`, `ocupado`, `afiliado_salud`, `regimen_salud`, `actividad_sem_`

pasada, log_meses_empresa, tamano_empresa, posicion_ocupacional, horas_trabajo_semana, arriendo_pc_sobre_lp, prop_ocupados_hogar, tenencia_vivienda, recibio_arriendos_pensiones y ayudas_instituciones. Las categóricas con códigos del DANE y las dummies entran como factores (en XGBoost, como una dummy por nivel). Los conjuntos x2 y x3 de XGBoost se describen en la Sección 4.3.

Cuadro 2: Mejores modelos por validación cruzada.

Modelo	Script	Hiperparámetros	Umbral	F_1
Naive Bayes	03_naive_bayes.r	laplace = 0	0,42	0,675
CART	04_carts.r	cp = 0,000025; gini; upsampling dentro de cada fold	0,61	0,670
XGBoost (x1)	05_xgboost.r	500 rondas; profundidad 6; eta = 0,1; min_child_weight = 50	0,29	0,693
XGBoost (x3)	05_xgboost.r	500 rondas; profundidad 6; eta = 0,1; min_child_weight = 50	0,32	0,706
XGBoost por hogar	05b_xgboost_hogar.r	categóricas nativas; eta = 0,02; profundidad 8; min_child_weight = 50; colsample = 0,5; ingreso predicho y modelo por persona con todas las preguntas	0,38	0,773

Las predicciones de test están en output/submissions/: NB_laplace_0_threshold_042.csv (naive Bayes), CART_up_cp_0000025_threshold_061.csv (CART), XGB_x1_nrounds_500_depth_6_eta_01_threshold_029.csv y XGB_x3_nrounds_500_depth_6_eta_01_threshold_032.csv (XGBoost por persona) y XGBH_nativo_G_eta002_depth6_col08_V4_mas_V4t_todo2_mas_V4f_af_depth8_mcw50_col05_threshold_038.csv (XGBoost por hogar, con CODIFICACION=nativo). Todas se regeneran al correr cada script, con semilla fija.

4.3. XGBoost por persona

05_xgboost.r estima XGBoost con caret y la misma evaluación por hogar. Como el método "xgbTree" de caret no funciona con xgboost 3, el script define el modelo para caret con los mismos siete hiperparámetros (xgb_caret); para cada combinación estima un solo modelo con el mayor nrounds y evalúa los menores con sus primeros árboles. El xgboost de CRAN para macOS no usa varios núcleos, así que los folds se estiman en paralelo (4 a la vez) y cada modelo fija su semilla (seed = 123).

La grilla (grid_xgb) tiene 16 combinaciones: nrounds $\in \{250, 500\}$, profundidad $\in \{4, 6\}$, eta $\in$ {0,05; 0,1} y min_child_weight $\in \{10, 50\}$, con colsample_bytree = 0,8 y

`subsample` = 0,63. Una grilla ampliada (hasta 1.500 rondas y profundidad 10) no mejoró el F_1 (0,6934 frente a 0,6929): con estas variables el modelo ya está en su techo.

Los conjuntos de variables son `x1` (las 16 de arriba); `x2`, que agrega `educ_max_adultos`, `linea_pobreza`, `cuartos_dormir`, `prop_dependientes` y `personas_hogar` (las más importantes del CART con todas las variables); y `x3`, que además agrega `dominio`, `depto` y `cabecera`. Cada uno se estimó con tres bases: la original, la aumentada (hogares pobres replicados hasta balancear las clases) y una sin el 10 % de hogares más ricos en el entrenamiento (la validación sí los incluye).

Cuadro 3: XGBoost por persona: F_1 de validación cruzada por conjunto de variables y base (en paréntesis, el umbral).

Conjunto	Base original	Base aumentada	Sin el 10 % más rico
`x1` (16 variables)	0,693 (0,29)	0,693 (0,64)	0,694 (0,29)
`x2` (21 variables)	0,702 (0,32)	0,702 (0,64)	0,702 (0,32)
`x3` (24 variables)	0,706 (0,32)	0,706 (0,63)	0,706 (0,33)

A diferencia del CART, XGBoost sí aprovecha las variables del hogar y la ubicación: `x3` mejora el F_1 en 0,013 frente a `x1`. La base no cambia el resultado: con la base aumentada el modelo da probabilidades más altas y el umbral óptimo sube en la misma proporción (de 0,32 a 0,63), y quitar a los hogares más ricos (ninguno es pobre) no le quita ni le agrega información útil. Las variables con más ganancia en `x3` son `arriendo_pc_sobre_lp` (31 %), `prop_ocupados_hogar` (24 %), `regimen_salud` (14 %), `educ_max_adultos` (7 %) y `tenencia_vivienda` (6 %).

4.4. XGBoost por hogar

`05b_xgboost_hogar.r` cambia la unidad del modelo: una fila por hogar, con la base de agregados de `01b_bases_hogar.r` (94 variables). Se usan los mismos 5 folds y la misma forma de calcular el F_1 que los modelos logit y LightGBM del equipo, para que los resultados sean comparables. Las variables que usan `pobre` o el ingreso (tasa de pobreza del oficio, ingreso predicho por persona y probabilidad por persona) se estiman con validación cruzada anidada: las del fold que se evalúa nunca usan su propia etiqueta. Cada modelo usa parada temprana (100 rondas) en su fold.

Cuadro 4: XGBoost por hogar: F_1 de validación cruzada (5 folds).

Prueba	Umbral	F_1
H0: base por hogar (94 variables)	0,38	0,7528
H1: + factor de expansión, mejor ocupado, oficio e ingreso predicho	0,36	0,7571
H2: + `educ_max_adultos` y coeficientes de variación	0,33	0,7568
H6: + productos, razones y variables relativas al dominio	0,37	0,7577
H7: + probabilidad por persona (stacking)	0,37	0,7589
Mejores hiperparámetros (`eta` 0,02; profundidad 6)	0,36	0,7598
Solo las 75 variables con más ganancia	0,39	0,7603
+ predicción de la regresión como variable (stacking)	0,37	0,7590
+ combinaciones de las variables más importantes	0,39	0,7593
+ logaritmos y cuadrados	0,37	0,7588
Regresión de log(ingreso / línea) ($R^2 = 0{,}70$)	0,34	0,7533
Combinación: clasificador, regresión y modelo por persona	0,36	0,7600

Modelar el hogar directamente es el mayor salto de todo el trabajo: de 0,706 (XGBoost por persona) a 0,753 con las mismas herramientas. Encima de eso, lo que más aporta es el ingreso predicho y el stacking con el modelo por persona, que juntos concentran el 84 % de la ganancia del mejor modelo. La base aumentada empeora el resultado (0,7536), la base sin los hogares más ricos lo deja igual (0,7592) y combinar con naive Bayes no aporta (su peso óptimo es 0). Tampoco ayudan más combinaciones no lineales de las variables más importantes ni sus logaritmos y cuadrados: XGBoost ya arma esas combinaciones con sus árboles, y una transformación monótona da los mismos cortes que la variable original.

Cuadro 5: XGBoost por hogar: F_1 de validación cruzada según cómo entran las variables categóricas.

Prueba	Códigos enteros	One-hot	Nativas
H0: base por hogar	0,7528	0,7532	0,7534
H1: + ingreso predicho y otras	0,7571	0,7589	0,7596
H7: + stacking por persona	0,7589	0,7601	0,7600
Mejor clasificador	0,7598	0,7605	0,7612
75 variables	0,7603	0,7591	0,7609
20 variables (afinado)	0,7553	0,7594	0,7580

Hasta aquí las categóricas (dominio, departamento, oficio, posición ocupacional, etc.) entraban como códigos enteros, como en el modelo LightGBM del equipo; LightGBM los trata como categorías, pero XGBoost los toma como números ordenados. El Cuadro 5 compara esa codificación con una variable dicotómica por nivel (one-hot) y con las categóricas nativas

de XGBoost. Las dos alternativas mejoran casi todas las pruebas, y el mejor modelo pasa de 0,7598 a 0,7612 con categóricas nativas. La ganancia viene sobre todo de los modelos por persona del ingreso predicho y del stacking (con el oficio, de 84 niveles): en la base por hogar sola (H0) la diferencia es de apenas 0,0005. Estandarizar las variables numéricas de la base por hogar no cambia nada (0,7608 frente a 0,7612): una transformación afín da los mismos cortes.

Cuadro 6: XGBoost por hogar: variables nuevas sobre el mejor clasificador (categóricas nativas, 130 variables). F_1 con el umbral escogido en los mismos folds y con el umbral honesto.

Prueba	F_1	F_1 honesto
Mejor clasificador	0,7612	0,7610
Ingreso predicho afinado (en vez del original)	0,7617	0,7613
Ingreso predicho con variables del hogar	0,7615	0,7611
Ingreso laboral y no laboral por separado	0,7615	0,7613
Ingreso predicho afinado + el original	0,7622	0,7622
+ probabilidad de ser indigente por persona	0,7607	0,7605
+ índices (promedio de variables estandarizadas)	0,7605	0,7599
+ índices supervisados (logit de `pobre`)	0,7607	0,7602
+ los dos tipos de índices	0,7610	0,7610
Todo junto	0,7619	0,7616

El Cuadro 6 prueba tres ideas más. Primero, mejorar el ingreso predicho por persona, que es la segunda fuente de ganancia del modelo: afinar sus hiperparámetros (`eta` 0,05, profundidad 10), darle además variables del hogar, o predecir por separado el ingreso laboral y el no laboral. Las tres versiones predicen un poco mejor el ingreso del hogar (R^2 de 0,520 a 0,523–0,534), pero el F_1 sube poco; lo que más ayuda es usar la versión afinada junto a la original (0,7622, +0,001, el límite de lo que se distingue del ruido). Segundo, un modelo por persona de indigencia, que no aporta: la probabilidad de ser pobre ya contiene esa información. Tercero, índices que resumen variables débiles del mismo tema (informalidad del empleo, capital humano, vivienda, ingresos no laborales y dependencia), ya sea como promedio de las variables estandarizadas o como la predicción de un logit de `pobre`. En el mejor modelo no aportan: con 130 variables y miles de árboles, el boosting ya suma esas señales débiles. Solo ayudan algo en un modelo de 20 variables, donde esas señales no están (0,7590 frente a 0,7580; honesto 0,7590 frente a 0,7576), pero sin llegar al modelo completo.

Cuadro 7: XGBoost por hogar: preguntas que no usaba ningún modelo, modelo por persona afinado, cortes de ingreso y random forest, sobre el mejor modelo anterior.

Prueba	F_1	F_1 honesto
Ingreso predicho afinado + el original	0,7622	0,7622
+ modelo por persona afinado	0,7625	0,7622
+ modelo por persona con las preguntas no usadas	0,7656	0,7649
+ ingreso predicho con las preguntas no usadas	0,7714	0,7708
+ probabilidad de ingreso menor a 0,8 y 1,25 líneas	0,7675	0,7675
Todo junto	0,7715	0,7708
Random forest con las mismas variables	0,7686	0,7684
XGBoost + random forest	0,7717	0,7717

Una revisión de las variables mostró 16 preguntas por persona que están en test y que ningún modelo usaba: pagos en especie, posición en el segundo trabajo, búsqueda de más horas o de otro trabajo, posición en el último trabajo e ingresos por trabajo de desocupados e inactivos. Con ellas, el ingreso predicho por persona pasa de un R^2 de 0,942 a 0,982 (el del ingreso del hogar, de 0,52 a 0,62), sobre todo porque identifican quién recibe ingresos sin estar ocupado, y el F_1 sube a 0,7714 (Cuadro 7): el mayor salto desde pasar a nivel hogar. Las preguntas tienen la misma frecuencia y distribución en train y en test, así que no hay fuga de información. Afinar el modelo por persona sin ellas no cambia nada, y las probabilidades de estar por debajo de 0,8 y 1,25 veces la línea ayudan menos que el ingreso. Un random forest (`ranger`, 500 árboles, `mtry` 30) con las mismas variables llega a 0,7686, y combinado con XGBoost a 0,7717, una diferencia dentro del ruido.

El análisis de errores del mejor modelo muestra dónde está el límite: el 30 % de los errores ocurre en hogares cuyo ingreso está a menos de 10 % de la línea (el 7 % de los hogares), y el 82 % a menos de 50 %. Justo al lado de la línea el modelo se equivoca en 40–46 % de los hogares, mientras que con ingresos de más del doble de la línea casi no se equivoca (0,6 %). Ningún grupo (ciudad, tamaño del hogar, ocupados, tenencia, sexo del jefe) concentra errores de forma llamativa.

Cuadro 8: XGBoost por hogar: pruebas para los hogares cerca de la línea y ajustes finales, sobre el mejor modelo del cuadro anterior ("todo junto").

Prueba	F_1	F_1 honesto
Todo junto (cuadro anterior)	0,7715	0,7708
Más peso a los hogares cerca de la línea (mejor de 4)	0,7712	0,7703
Regresión del ingreso con las variables nuevas (R^2 = 0,835)	0,7684	0,7684
+ ingreso predicho con las preguntas no usadas, afinado	0,7731	0,7721
con profundidad 8, `min_child_weight` 50, `colsample` 0,5	0,7733	0,7724
solo las 75 variables con más ganancia	0,7727	0,7721
combinado con random forest	0,7734	0,7734
con un modelo especialista para los hogares dudosos	0,7726	0,7726

Como la mayoría de los errores está cerca de la línea, el Cuadro 8 prueba dos formas de concentrar el modelo en esos hogares, usando el ingreso real solo para entrenar: darles más peso en el entrenamiento y un segundo modelo, entrenado solo con los hogares a los que el primero da una probabilidad intermedia (entre 0,10 y 0,85), que vuelve a predecirlos. Ninguna ayuda: lo que queda cerca de la línea no se distingue con estas variables. Lo que sí suma algo es afinar el ingreso predicho con las preguntas nuevas (con variables del hogar y por componentes, R^2 por hogar de 0,62 a 0,63) y usarlo junto al anterior, con lo que el mejor modelo llega a 0,7733. Los hiperparámetros, la selección de variables y la combinación con random forest o con la regresión cambian el F_1 en menos de 0,001.

Para descartar que la mejora dependa de la partición en folds, el mejor modelo y el anterior a las preguntas nuevas se estimaron con otras dos particiones, recalculando todas las variables de la validación cruzada anidada. El mejor modelo les gana por 0,011, 0,012 y 0,012 en las tres particiones, y su F_1 es de 0,7733, 0,7749 y 0,7735.

Dos verificaciones dan una idea de qué tan confiables son estas diferencias. Con el umbral escogido de forma honesta (con los otros 4 folds), el F_1 del mejor modelo baja solo de 0,7598 a 0,7593. Y con otras tres particiones en folds, el F_1 del mejor modelo varía con una desviación estándar de 0,0003, y su mejora sobre H1 es de 0,0025 en promedio, positiva en las cuatro: las diferencias de menos de 0,001 entre modelos son ruido.

4.5. Cómo replicarlos

Desde la raíz del repositorio:

1. `Rscript script/01_data_cleaning.r`: crea las bases limpias (`data/train_clean.rds`, `data/test_clean.rds` y `data/train_clean_augmented.rds`).

2. **Naive Bayes:** `Rscript script/03_naive_bayes.r`. La sección 4 hace el grid search

de `laplace` y umbral, y la sección 5 guarda la submission con el nombre de los hiperparámetros elegidos.

3. **CART:** `Rscript script/04_carts.r`. La sección 4 estima `cv_arbol(x1, "up")`, que elige `cp` y umbral por validación cruzada; la sección 5 guarda la submission.

4. **XGBoost:** `Rscript script/05_xgboost.r`. La sección 4 estima `cv_xgb(x1)` (o `cv_xgb(x3)`, o con `base = "train_clean_augmented"`), que elige los hiperparámetros y el umbral por validación cruzada; la sección 5 guarda la submission.

5. **XGBoost por hogar:** primero `Rscript output/pruebas/hogar/01b_bases_hogar_main.r` (crea `data/train_hogar.rds` y `data/test_hogar.rds`) y después `Rscript script/05b_xgboost_hogar.r`. Cada prueba se guarda en `output/pruebas/xgb_hogar/`, así que volver a correrlo solo estima lo que falte; la sección 6 guarda la submission.

4.6. Importancia de las variables

Para medir qué variables son más relevantes se estimó un CART con todas las variables disponibles (una versión por concepto), 66 interacciones entre las numéricas centrales y algunas razones (146 columnas), con la base aumentada y un grid search de `cp`, `minbucket`, criterio de partición, `maxdepth`, `maxsurrogate` y umbral (código en `output/pruebas/todas/`). El mejor modelo (`minbucket` = 100, entropía, `maxdepth` = 15, 5 cortes sustitutos, umbral 0,70) tiene un F_1 de 0,670, igual al CART con 16 variables. Un CART solo con las seis variables y las tres interacciones más importantes del Cuadro 9, con la misma grilla, llega a un F_1 de 0,641 (código en `output/pruebas/top9/`): las demás variables sí aportan.

El Cuadro 9 muestra la importancia por reducción de la impureza, normalizada para que sume 100. La importancia de cada interacción se reparte por partes iguales entre las variables que la forman. La columna "rpart" suma los cortes principales y los sustitutos; "cortes principales" cuenta solo los cortes que el árbol usa.

Cuadro 9: Importancia de las variables (reducción de impureza, suma 100).

Variable	rpart	Cortes principales
`prop_ocupados_hogar`	29,5	21,6
`arriendo_pc_sobre_lp`	17,5	15,6
`educ_max_adultos`	10,6	21,4
`linea_pobreza`	9,8	8,7
`cuartos_dormir`	5,6	0,4
`regimen_salud`	4,5	15,2
`anos_educ_imp`	3,9	0,2
`prop_dependientes`	3,5	0,3
`personas_hogar`	3,3	0,6
`anos`	2,0	0,9
`tenencia_vivienda`	1,6	5,3

La interacción más importante es educación máxima de los adultos por proporción de ocupados del hogar: concentra el 40 % de la reducción de impureza en los cortes principales. Las interacciones y razones suman el 70 % de la importancia (rpart).