¿Quién es pobre en Colombia?

Predicción de la pobreza monetaria con la GEIH 2018: validación, herramientas e intuición económica

Maria Jose Perez Juan Manuel Lozano Samuel Suárez Valle

27 de octubre de 2026

Big Data y Machine Learning Aplicado a la Economía
Universidad de los Andes

Overview

Overview: qué hicimos y qué aprendimos

Modelo ganador

XGBoost por hogar (163 variables) alimentado por modelos por persona (ingreso con pérdida **Tweedie**, probabilidad de pobreza) y combinado 70/30 con una regresión del ingreso. Umbral 0,39.

F_1 validación cruzada (5 folds)	**0,7775**
F_1 con umbral honesto	0,7775
Kaggle (public leaderboard)	**0,7775**

Takeaways

1. Con IA, combinar variables ya no diferencia: todos los grupos llegan a F_1 parecidos con los mismos datos.
2. Ganamos con tres pilares: VALIDACIÓN HERRAMIENTAS INTUICIÓN ECONÓMICA
3. La pobreza es **del hogar** y la explica el **trabajo**: formalidad, ocupación e ingresos no laborales.
4. Educación, salud y subsidios casi no predicen el ingreso: pobreza monetaria $\neq$ multidimensional.

Datos

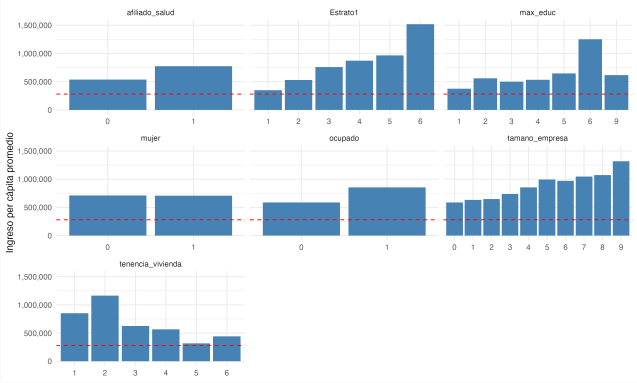
Datos: por qué estas variables

GEIH 2018 (DANE): **543.103 personas**, **164.958 hogares**, 20,0 % de hogares pobres. Pobre $\iff$ ingreso per cápita de la unidad de gasto *con arriendo imputado* $<$ línea de pobreza del dominio.

Bloque	Mecanismo económico	Sustento
Mercado laboral	El trabajo es la principal fuente de ingreso; la informalidad separa ingresos estables de precarios	MESEP (2012); Fernández y Villar (2017)
Ingresos no laborales	Pensiones, arriendos, remesas, ayudas: ingreso sin estar ocupado	DANE (2019)
Vivienda y arriendo	El arriendo imputado *entra* en la definición de ingreso del DANE	MESEP (2012)
Demografía	El mismo ingreso, dividido entre más miembros y menores	Ravallion (2016)
Capital humano y salud	Retornos a la educación; régimen de salud como proxy de formalidad	Angulo et al. (2016)

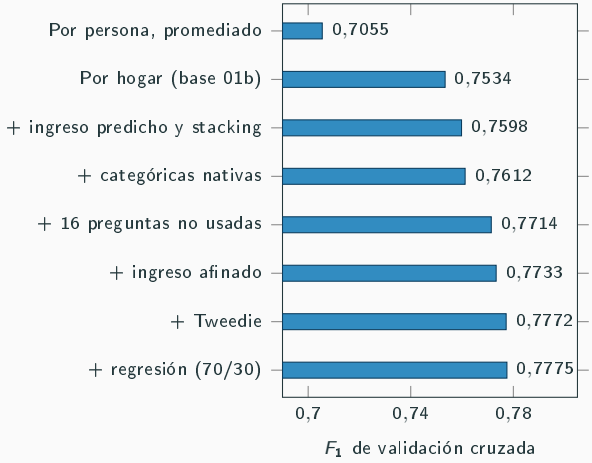
INTUICIÓN ECONÓMICA Ningún monto de ingreso está en test: el modelo *reconstruye* el ingreso con las preguntas que sí están.

Datos: qué revelaron los datos



- El ingreso sube con el **tamaño de la empresa** (proxy de formalidad), la educación superior y estar ocupado.
- El sexo de la persona casi no lo cambia.
- Ocupados del hogar y arriendo por persona: 47 % de la reducción de impureza en un CART exploratorio.
- Ingreso **muy asimétrico** y con muchos ceros: motiva la pérdida Tweedie.

El pivote: la pobreza es del hogar



Fase 1 (fallida): modelar a cada persona y promediar en el hogar: techo de 0,706.

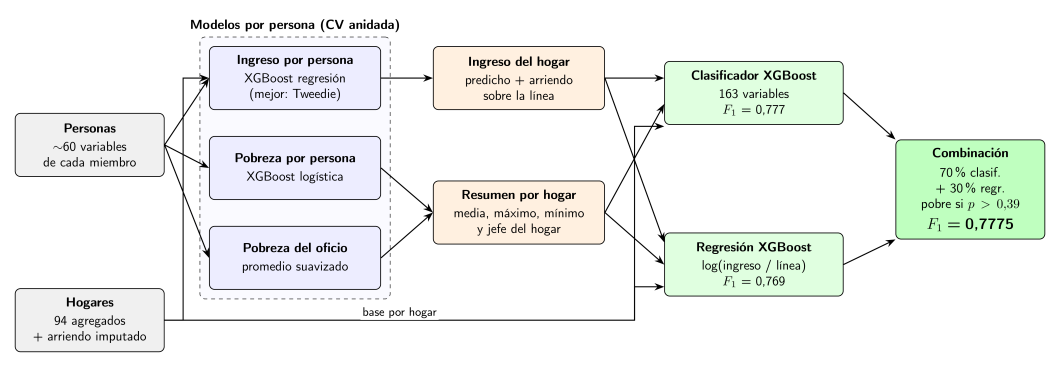
Fase 2 (pivote): una fila por hogar con sumas de dummies, índices y promedios grupales: +0,05 de F_1.

INTUICIÓN ECONÓMICA

Contraste: más combinaciones de variables (interacciones, logs, cuadrados, índices) no suman: los árboles ya las construyen.

Mejor modelo

Estructura del modelo final



Tres niveles: (1) modelos por persona con validación cruzada anidada; (2) resúmenes por hogar (suma, máximo, mínimo, el del jefe); (3) clasificador y regresión por hogar, combinados.

Entrenamiento: una validación concienzuda

- **Folds por hogar** (5): todos los miembros en el mismo fold.
- **CV anidada**: el ingreso predicho y la probabilidad por persona usan la etiqueta, así que se estiman sin ver el fold evaluado.
- **Parada temprana**: 100 rondas sin mejorar la log-loss.
- **Umbral** escogido por F_1 (grilla 0,10–0,85).

¿Cuánto creerle a una mejora?

- F_1 **honesto**: optimismo $\leq$ 0,0005.
- **Otras particiones**: 0,7775 / 0,7784 / 0,7767.
- Kaggle público = 20 % de test, DE $\approx$ 0,006: no distingue mejoras de 0,001. **Se decide por CV**.

Optimización: hiperparámetros y funciones de pérdida

HERRAMIENTAS

Clasificador por hogar

`eta` (learning rate)	0,02
`max_depth`	8
`min_child_weight`	50
`colsample_bytree`	0,5
`subsample`	0,8
árboles (parada temprana)	613–869
`gamma` / `lambda` / `alpha`	0 / 1 / 0

Superficie plana (0,772–0,773). `lambda` (L2) y `alpha` (L1) **fijos** desde iteraciones previas, para aislar lo nuevo.

1. Ingreso por persona con Tweedie ($\rho = 1{,}2$; laboral y no laboral)

$$L(y,\mu) = -\frac{y\,\mu^{1-\rho}}{1-\rho} + \frac{\mu^{2-\rho}}{2-\rho}$$

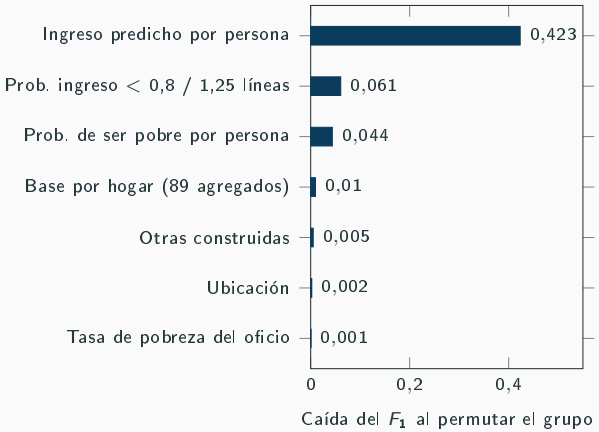
Predice la *media* en pesos (no la mediana) y admite ceros: R^2 del hogar 0,63 → 0,66; F_1 0,7733 → **0,7772**.

2. Pesos en la regresión, $z = \log(\text{ingreso/línea})$:

$$w_i = 1 + 3\,e^{-|z_i|/0{,}25}$$

Más peso cerca de la línea, de los dos lados. Final: $p = 0{,}7\,p_{\text{clasif}} + 0{,}3\,p_{\text{regr}}$; pobre si $p > 0{,}39$.

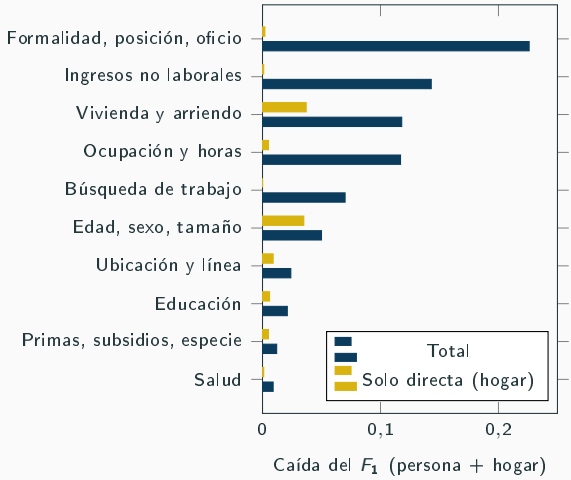
Feature importance: permutaciones por grupo



- Se permuta el grupo en el fold de validación (5 folds $\times$ 3) y se mide la caída del F_1.
- Sin el ingreso predicho, el F_1 cae de 0,778 a 0,35.
- Variable más importante: ingreso Tweedie + arriendo imputado por persona sobre la línea, la fórmula del DANE ($-0{,}043$).

INTUICIÓN ECONÓMICA

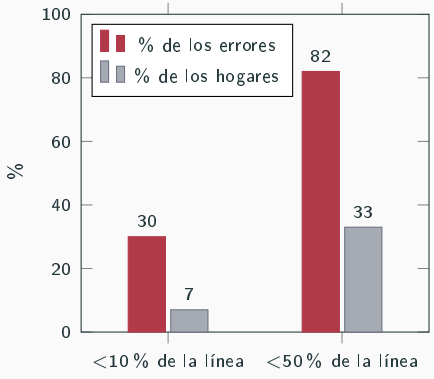
Feature importance de extremo a extremo: por concepto



- **Mercado laboral**: lo que más pesa (0,07–0,23); casi todo pasa *por los modelos por persona*.
- **Ingresos no laborales y vivienda**: segundo bloque (0,12–0,14).
- **Capital humano y protección social**: $\leq 0{,}021$; su información ya está en el trabajo.

Las importancias no se suman: los conceptos están correlacionados.

Diagnósticos: dónde se equivoca el modelo



- Al lado de la línea el modelo falla en el 40–46 % de los hogares; con más del doble de la línea, en el 0,6 %.
- Ni pesos cerca de la línea ni un modelo "especialista" ayudan: con estas variables, ese error es **irreducible**.
- Ningún grupo concentra errores de forma llamativa.
- Sin fuga: las 16 preguntas nuevas tienen la misma distribución en train y en test.

VALIDACIÓN

Implicaciones de política

Del F_1 a la focalización: leakage vs. undercoverage

Umbral 0,39, predicciones fuera de muestra:

- **Cobertura** $\approx$81 % $\Rightarrow$ undercoverage $\approx$19 %.
- **Precisión** $\approx$75 % $\Rightarrow$ leakage: 1 de cada 4 beneficiarios no es pobre.
- El F_1 pesa igual los dos errores; un programa no tiene por qué: el umbral es una **decisión de política**.

Rural, informal y hogares grandes: más *inclusión*. Pobres "que no lo parecen" (jefe formal o educado, hogar pequeño): más *exclusión*. Jefa mujer: +3,8 pp de detección. Son tasas base distintas, no una regla discriminatoria (Kleinberg et al., 2017).

Atributo	Grupo	% pobres	Sensib.	Falsos pos.
Sexo del jefe	Hombre	18,3	78,9	6,2
	Mujer	22,4	82,7	7,4
Empleo del jefe	Formal	5,6	**65,1**	1,7
	Informal	26,1	80,2	**10,1**
Zona	Cabecera	19,0	80,8	6,2
	Rural	30,0	80,0	**12,6**
Educación jefe	Superior	7,3	**65,4**	2,3
	Primaria o menos	28,8	83,4	10,8
Tamaño	1 o 2 personas	10,7	**66,5**	3,8
	5 o más	35,8	88,8	**12,1**

Pobreza monetaria, focalización y costo de operación

Qué mide el modelo

- Solo **pobreza monetaria**: educación, salud y subsidios casi no aportan una vez se conoce el trabajo.
- IPM y pobreza monetaria capturan privaciones distintas (Angulo et al., 2016): focalizar ingreso con indicadores de salud o educación genera errores.
- Proxies observables son manipulables (Camacho y Conover, 2011).

¿Encuesta corta y barata?

+ No pregunta **montos de ingreso** (lo más caro y subdeclarado): basta el módulo laboral, la vivienda y fuentes de ingreso sí/no.
– Necesita el módulo laboral de *cada miembro* (∼60 preguntas por persona): costo similar a una visita SISBÉN.
– Formalidad verificable con PILA; ingresos no laborales y búsqueda de trabajo, no.
• Reentrenar si cambian la línea o el mercado laboral (datos de 2018).

Cierre: qué nos hizo ganar

VALIDACIÓN

CV anidada sin fuga, folds por hogar, F_1 honesto y ruido medido. Decidimos con la CV, no con el leaderboard.

HERRAMIENTAS

Categóricas nativas, pérdida Tweedie, stacking con modelos por persona y parada temprana.

INTUICIÓN ECONÓMICA

La pobreza es del hogar; el arriendo imputado reproduce la regla del DANE; 16 preguntas del cuestionario que nadie usaba.

Con la IA, cualquiera combina variables.

La ventaja está en saber qué preguntar y en cómo comprobarlo.

Referencias

- Angulo, R., Díaz, Y. y Pardo, R. (2016). The Colombian Multidimensional Poverty Index: Measuring poverty in a public policy context. *Social Indicators Research*, 127(1), 1–38.
- Camacho, A. y Conover, E. (2011). Manipulation of social program eligibility. *American Economic Journal: Economic Policy*, 3(2), 41–65.
- Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, 785–794.
- CONPES 3877 (2016). Declaración de importancia estratégica del Sistema de Identificación de Potenciales Beneficiarios (SISBÉN IV). DNP.
- DANE (2019). Pobreza monetaria y multidimensional en Colombia 2018. Boletín técnico.
- DANE y DNP (2012). Misión para el Empalme de las Series de Empleo, Pobreza y Desigualdad (MESEP): metodología de pobreza monetaria.
- Fernández, C. y Villar, L. (2017). The impact of lowering the payroll tax on informality in Colombia. *Economía*, 18(1), 125–155.
- Grosh, M. y Baker, J. (1995). Proxy means tests for targeting social programs. LSMS Working Paper 118, Banco Mundial.
- Kleinberg, J., Ludwig, J., Mullainathan, S. y Obermeyer, Z. (2015). Prediction policy problems. *American Economic Review*, 105(5), 491–495.
- Kleinberg, J., Mullainathan, S. y Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. *ITCS*.
- Ravallion, M. (2016). *The Economics of Poverty*. Oxford University Press.