¿Quién es pobre en Colombia?

Predicción de la pobreza monetaria con la GEIH 2018

Maria Jose Perez Juan Manuel Lozano Samuel Suárez Valle

27 de octubre de 2026

Big Data y Machine Learning Aplicado a la Economía
Universidad de los Andes

Overview

Overview: qué alimenta el modelo

1. **Base por hogar** (89 agregados de los miembros): trabajo, demografía, vivienda, ingresos no laborales, ubicación y línea.
2. **Modelos por persona** (validación cruzada anidada): ingreso laboral y no laboral con pérdida Tweedie; probabilidad de ser pobre; probabilidad de ingreso bajo 0,8 y 1,25 líneas; tasa de pobreza del oficio. Se resumen por hogar: suma, mínimo, máximo, promedio y el del jefe.
3. **Ingreso predicho + arriendo imputado**, por persona y sobre la línea: la fórmula del DANE con el ingreso predicho.
4. **Clasificador XGBoost por hogar** con las 163 variables.
5. **Regresión** de log(ingreso/línea), con más peso cerca de la línea.
6. **Combinación**: $p = 0{,}7\, p_{\text{clasif.}} + 0{,}3\, p_{\text{regr.}}$; pobre si $p > 0{,}39$.

F_1 de validación cruzada	**0,7775**

5 folds por hogar, datos públicos de train.

Con la IA, combinar variables está al alcance de todos: los grupos llegan a F_1 parecidos con los mismos datos.

Lo que nos diferenció fue la **validación**, el **uso de las herramientas** y la **intuición económica**.

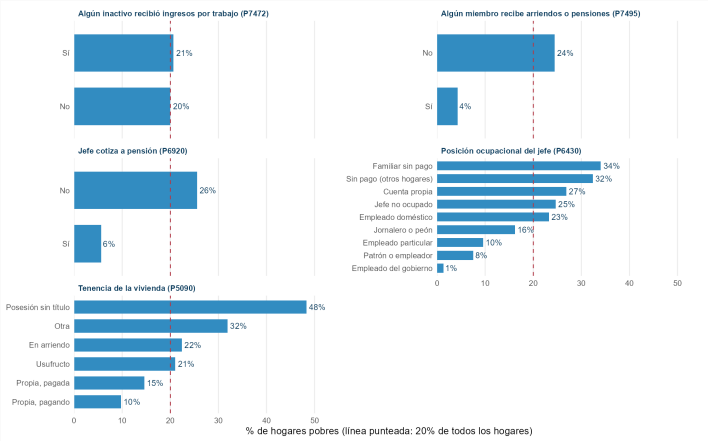
Datos

Intuición económica: qué predecir, no qué variables meter

GEIH 2018: **543.103 personas en 164.958 hogares**; 20,0 % de los hogares son pobres. Un hogar es pobre si su ingreso per cápita (con arriendo imputado) es menor que la línea de su dominio. Ningún monto de ingreso está en test (MESEP, DANE y DNP, 2012).

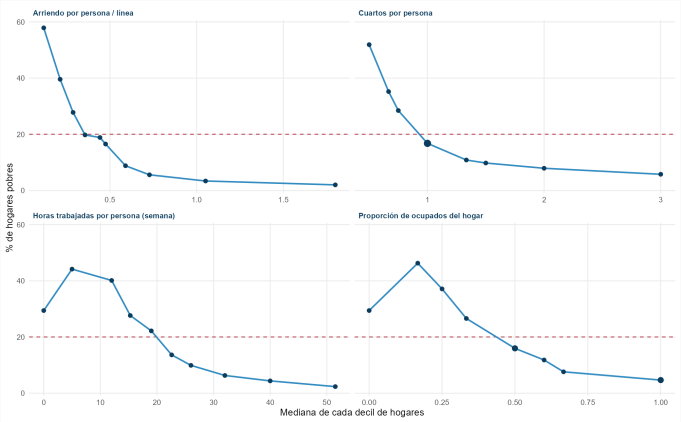
Hecho económico	Decisión de modelación	Efecto
La pobreza se mide en la *unidad de gasto*, no en la persona	Una fila por hogar: los ingresos de los miembros se suman y se reparten	F_1 0,706 $\rightarrow$ 0,753, el mayor salto
La regla es una *fórmula*: (ingreso + arriendo imputado) / personas $<$ línea	Predecir el *ingreso* y reconstruir la regla, en vez de predecir solo la etiqueta	El ingreso predicho resume casi todo (sin él, F_1 0,35)
El ingreso tiene muchos ceros y una cola larga; para sumar miembros se necesita la *media*	Pérdida Tweedie para el ingreso por persona (la cuadrática sobre el log predice la mediana)	R^2 del hogar 0,63 $\rightarrow$ 0,66; F_1 +0,004
Hay ingresos sin empleo: pensiones, arriendos, trabajos de inactivos	Usar las preguntas del cuestionario que identifican quién recibe ingresos sin estar ocupado	R^2 por persona 0,94 $\rightarrow$ 0,98; F_1 +0,009
La clasificación solo es difícil *cerca de la línea*	Más peso a esos hogares en la regresión del ingreso	Entra en la combinación 70/30

Datos: los predictores que importan, por categoría



Las preguntas con mayor importancia en el modelo (ver la sección de importancia): la **posición ocupacional** separa más que cualquier otra; recibir **arriendos o pensiones** y la **formalidad del jefe** marcan a los hogares no pobres.

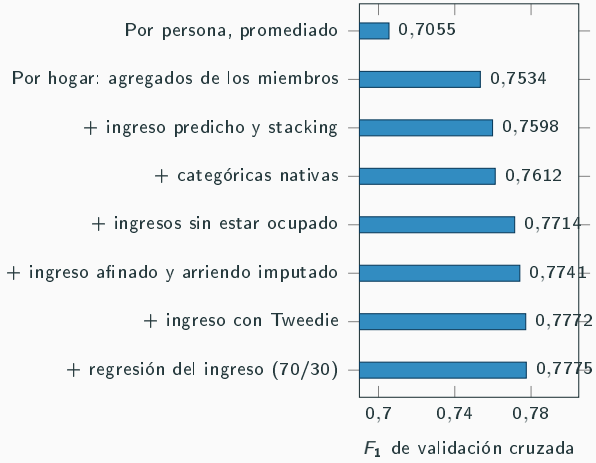
Datos: los predictores que importan, continuos



- La pobreza cae rápido con el **arriendo por persona**, las **horas** y los **ocupados**, y después se aplana: relaciones *no lineales* y con umbrales.
- Muchos hogares con cero horas u ocupados: una masa en cero que un modelo lineal no captura bien.
- Esa forma es la que aprovechan los árboles.

Línea punteada: 20 % de hogares pobres.

El pivote: de la persona al hogar



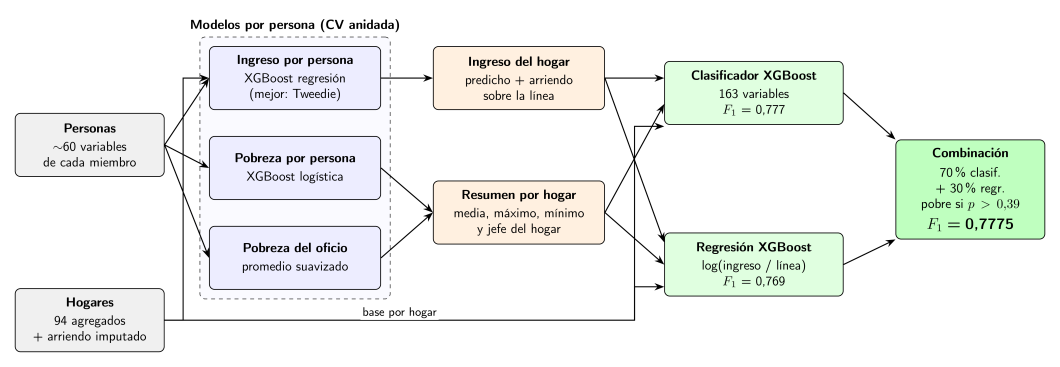
Fase 1: modelar a cada persona y promediar en el hogar. Techo de 0,706.

Fase 2 (pivote): una fila por hogar, con sumas, proporciones y los datos del jefe: +0,05 de F_1.

Después: cada escalón agrega *información* sobre el ingreso del hogar, no combinaciones de variables. Logaritmos, cuadrados, índices e interacciones no sumaron: los árboles ya las construyen.

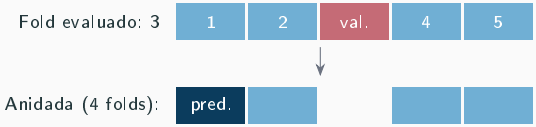
Mejor modelo

Estructura del modelo final



Tres niveles: (1) modelos por persona con validación cruzada anidada; (2) resúmenes por hogar (suma, máximo, mínimo, el del jefe); (3) clasificador y regresión por hogar, combinados.

Validación: cómo se mide sin hacer trampa



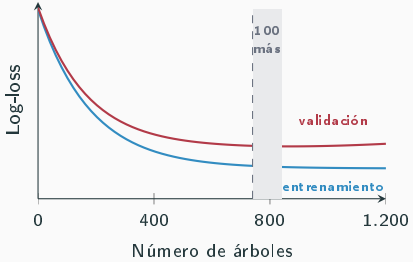
Cada parte oscura se predice con modelos entrenados en las otras tres: el ingreso predicho nunca vio la etiqueta de su hogar.

Folds **por hogar**: todos los miembros en el mismo fold. El fold rojo nunca entra en el entrenamiento de *ningún* nivel.

- **5 folds por hogar**: se entrena con 4 y se mide con el quinto, cinco veces.
- **Validación anidada**: el ingreso predicho y la probabilidad por persona usan la etiqueta. Dentro de los 4 folds de entrenamiento se repite la partición, para que esas variables también sean fuera de muestra.
- Toda mejora se compara con los **mismos folds**; se repitió con otras dos particiones (0,7784 y 0,7767).

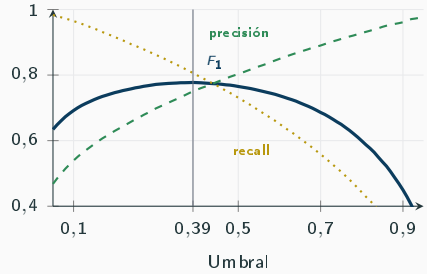
Parada temprana y umbral

Parada temprana: cuántos árboles



Cada árbol nuevo corrige el error de los anteriores. Se para cuando la log-loss del fold de validación lleva **100 árboles** sin mejorar, y se usa el mejor (613–869 árboles según el fold). Más árboles solo memorizan el entrenamiento.

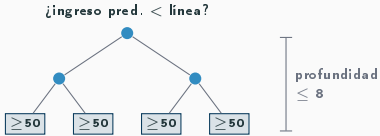
Umbral: cuándo decir "pobre"



El modelo da una probabilidad; el umbral la vuelve una decisión. Subirlo gana precisión y pierde recall. Se escoge el que maximiza el F_1 promedio de los 5 folds: **0,39**, no 0,5, porque solo el 20 % de los hogares es pobre y el F_1 premia encontrarlos.

Hiperparámetros: qué controla cada uno

Parámetro	Valor	Intuición
`eta`	0,02	Tamaño del paso: cada árbol corrige solo el 2 % del error. Pasos cortos, más árboles, menos sobreajuste
`max_depth`	8	Hasta 8 preguntas por rama: interacciones de hasta 8 variables (ingreso × tenencia × tamaño…)
`min_child_weight`	50	Una hoja necesita suficiente evidencia ($\approx$ 50 hogares con duda): no se crean reglas para casos aislados
`colsample_bytree`	0,5	Cada árbol ve la mitad de las variables: obliga a usar señales distintas
`subsample`	0,8	Cada árbol ve el 80 % de los hogares: más azar, menos varianza
árboles	613–869	Los fija la parada temprana
`gamma, lambda, alpha`	0, 1, 0	Penalizaciones fijas desde iteraciones previas



cada árbol aprende el error que dejaron los anteriores (columnas y hogares al azar)

La superficie es plana: entre las mejores combinaciones el F_1 solo va de 0,772 a 0,773. Los hiperparámetros *no* fueron la fuente de la ganancia.

Funciones de pérdida y pesos de la combinación

1. Ingreso por persona con pérdida Tweedie

($\rho = 1{,}2$; laboral y no laboral por separado)

$$L(y, \mu) = -\frac{y\,\mu^{1-\rho}}{1-\rho} + \frac{\mu^{2-\rho}}{2-\rho}$$

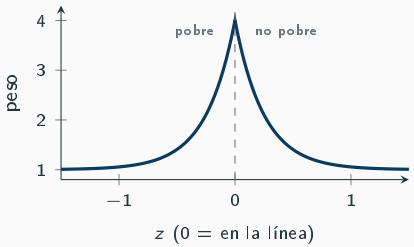
Entre la Poisson y la Gamma: admite ceros y una cola larga, y predice la *media* en pesos. Al sumar a los miembros, el ingreso del hogar ya no queda subestimado: R^2 0,63 $\rightarrow$ 0,66; F_1 0,7733 $\rightarrow$ 0,7772.

3. Combinación 70/30

La regresión se pasa a probabilidad con un logit de `pobre` sobre su predicción. Luego $p = w\,p_{\text{clasif.}} + (1-w)\,p_{\text{regr.}}$, con w y el umbral escogidos juntos por F_1: $w = 0{,}7$, umbral 0,39.

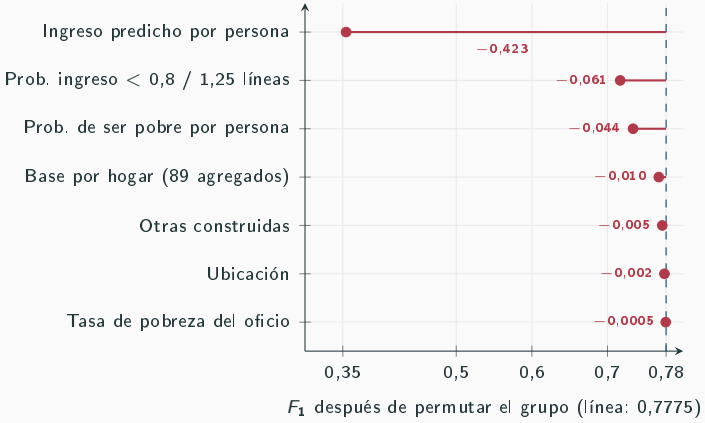
2. Regresión de $z = \log(\text{ingreso/línea})$ con pesos

$$w_i = 1 + 3\,e^{-|z_i|/0{,}25}$$



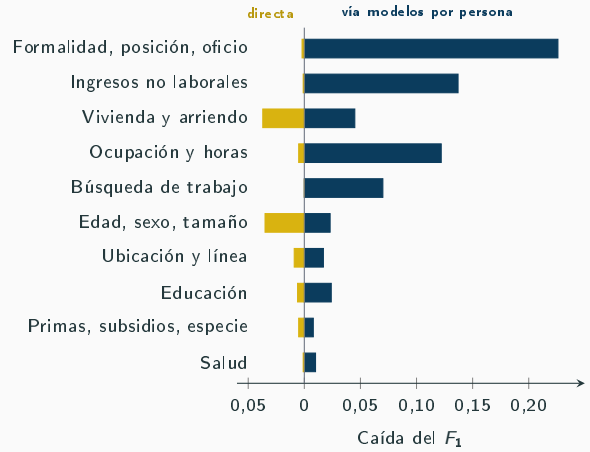
Un hogar en la línea pesa 4; uno al doble de la línea, casi 1. La regresión se concentra donde se decide la clasificación. Se escogió entre amplitudes $\{1, 3\}$ y anchos $\{0{,}25;\ 0{,}5\}$.

Importancia por permutación: qué le resta al modelo quitar cada grupo



- Se desordena el grupo entre los hogares del fold de validación y se mide cuánto cae el F_1 (5 folds $\times$ 3 permutaciones).
- Sin el **ingreso predicho**, el F_1 cae a 0,35: es el corazón del modelo.
- La variable individual más importante es la fórmula del DANE con el ingreso predicho ($-0{,}043$).
- De 163 variables, **21 no aportan** o restan: quitarlas no cambiaría nada.

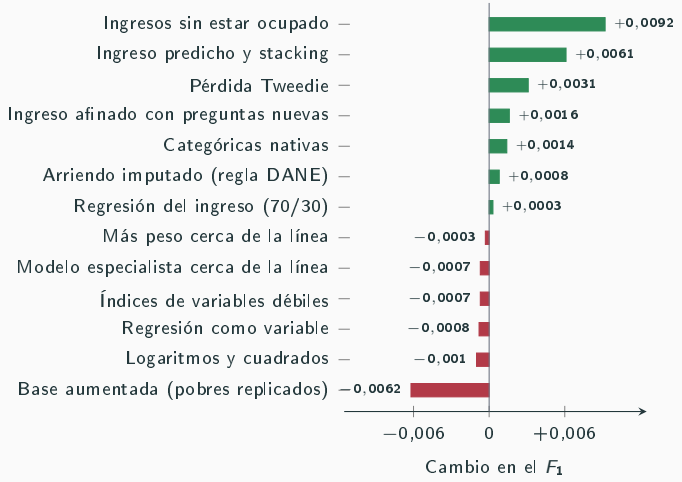
Importancia de extremo a extremo: por dónde entra cada concepto



- Se permuta el concepto en las personas y en el hogar, y se recalcula toda la cadena.
- El **trabajo** pesa más, y casi todo entra *a través del ingreso predicho*.
- Solo la **vivienda** y el **tamaño** entran directo: la fórmula suma el arriendo y divide entre personas.
- Educación y salud: $\leq 0{,}024$. Su información ya está en el trabajo.

Los efectos no se suman: los conceptos están correlacionados.

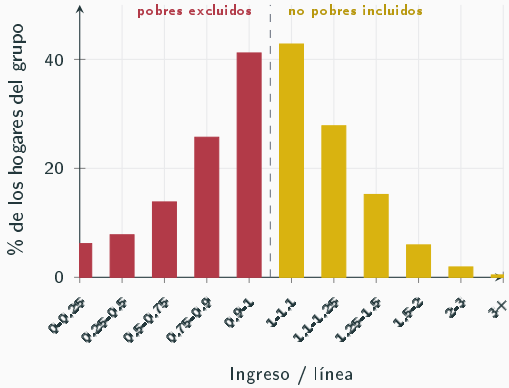
Qué sumó y qué restó en el camino



- **Sumó**: todo lo que mejora la *medición del ingreso* del hogar.
- **Restó o no cambió**: más transformaciones de las mismas variables, rebalancear la muestra y modelos extra cerca de la línea.
- Cambios de menos de 0,001 están dentro del ruido entre particiones.

Cada barra compara con el mejor modelo de ese momento (cuadros de `resultados.tex`).

Diagnósticos: dónde se equivoca el modelo



- A cada lado de la línea el modelo falla en **cerca de 4 de cada 10** hogares; al doble de la línea, casi nunca.
- Los errores se reparten: a la izquierda excluye pobres, a la derecha incluye no pobres.
- Ni más peso cerca de la línea ni un modelo especialista lo corrigen: con estas preguntas, ese error es **irreducible**.
- Sin fuga: las preguntas añadidas tienen la misma distribución en train y en test.

Implicaciones de política

Del F_1 a la focalización: leakage vs. undercoverage

Umbral 0,39, predicciones fuera de muestra:

- **Cobertura** $\approx$81 % $\Rightarrow$ **undercoverage** $\approx$19 %.
- **Precisión** $\approx$75 % $\Rightarrow$ **leakage**: 1 de cada 4 beneficiarios no es pobre.
- El F_1 pesa igual los dos errores; un programa no tiene por qué: el umbral es una **decisión de política**.

Rural, informal y hogares grandes: más *inclusión*. Pobres "que no lo parecen" (jefe formal o educado, hogar pequeño): más *exclusión*. Jefa mujer: +3,8 pp de detección. Son tasas base distintas, no una regla discriminatoria (Kleinberg et al., 2017).

Atributo	Grupo	% pobres	Sensib.	Falsos pos.
Sexo del jefe	Hombre	18,3	78,9	6,2
	Mujer	22,4	82,7	7,4
Empleo del jefe	Formal	5,6	**65,1**	1,7
	Informal	26,1	80,2	**10,1**
Zona	Cabecera	19,0	80,8	6,2
	Rural	30,0	80,0	**12,6**
Educación jefe	Superior	7,3	**65,4**	2,3
	Primaria o menos	28,8	83,4	10,8
Tamaño	1 o 2 personas	10,7	**66,5**	3,8
	5 o más	35,8	88,8	**12,1**

Pobreza monetaria, focalización y costo de operación

Qué mide el modelo

- Solo **pobreza monetaria**: educación, salud y subsidios casi no aportan una vez se conoce el trabajo.
- IPM y pobreza monetaria capturan privaciones distintas (Angulo et al., 2016): focalizar ingreso con indicadores de salud o educación genera errores.
- Proxies observables son manipulables (Camacho y Conover, 2011).

¿Encuesta corta y barata?

+ No pregunta **montos de ingreso** (lo más caro y subdeclarado): basta el módulo laboral, la vivienda y fuentes de ingreso sí/no.

– Necesita el módulo laboral de *cada miembro* ($\sim$60 preguntas por persona): costo similar a una visita SISBÉN.

– Formalidad verificable con PILA; ingresos no laborales y búsqueda de trabajo, no.

• Reentrenar si cambian la línea o el mercado laboral (datos de 2018).

Cierre: qué nos hizo ganar

Validación

Folds por hogar, validación cruzada anidada sin fuga, la misma partición para comparar todo y otras particiones para confirmar. Decidimos con la validación cruzada.

Uso de las herramientas

Categóricas nativas, pérdida Tweedie, stacking con modelos por persona, parada temprana y pesos cerca de la línea.

Intuición económica

Modelar el hogar, predecir el ingreso y reconstruir la regla del DANE con el arriendo imputado, y buscar en el cuestionario los ingresos sin empleo.

Con la IA, cualquiera combina variables.

La ventaja está en saber qué predecir y en cómo comprobarlo.

Referencias

Angulo, R., Díaz, Y. y Pardo, R. (2016). The Colombian Multidimensional Poverty Index: Measuring poverty in a public policy context. *Social Indicators Research*, *127*(1), 1–38.

Camacho, A. y Conover, E. (2011). Manipulation of social program eligibility. *American Economic Journal: Economic Policy*, *3*(2), 41–65.

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD* (pp. 785–794).

CONPES 3877 (2016). *Declaración de importancia estratégica del Sistema de Identificación de Potenciales Beneficiarios (SISBÉN IV)*. DNP.

DANE (2019). *Pobreza monetaria y multidimensional en Colombia 2018* [Boletín técnico].

DANE y DNP (2012). *Misión para el Empalme de las Series de Empleo, Pobreza y Desigualdad (MESEP): metodología de pobreza monetaria*.

Fernández, C. y Villar, L. (2017). The impact of lowering the payroll tax on informality in Colombia. *Economía*, *18*(1), 125–155.

Grosh, M. y Baker, J. (1995). *Proxy means tests for targeting social programs* (LSMS Working Paper 118). Banco Mundial.

Kleinberg, J., Ludwig, J., Mullainathan, S. y Obermeyer, Z. (2015). Prediction policy problems. *American Economic Review, 105*(5), 491–495.

Kleinberg, J., Mullainathan, S. y Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. En *8th Innovations in Theoretical Computer Science Conference (ITCS)*.

Ravallion, M. (2016). *The economics of poverty: History, measurement, and policy*. Oxford University Press.