¿Por qué XGBoost? Comparación de modelos

Predicción de la pobreza monetaria con la GEIH 2018:
precisión, interpretabilidad y política pública

Maria Jose Perez Juan Manuel Lozano Samuel Suárez Valle

27 de octubre de 2026

Big Data y Machine Learning Aplicado a la Economía
Universidad de los Andes

El modelo ganador

Overview: el modelo que elegimos

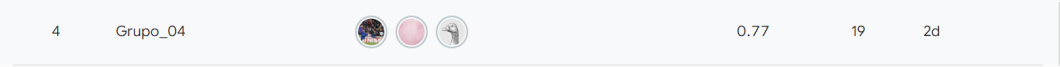
XGBoost por hogar

- 163 variables; `eta` 0,02, profundidad 8, `mcw` 50, `colsample` 0,5.
- Modelos por persona (CV anidada): ingreso **Tweedie** y probabilidad de ser pobre.
- 70/30 con una regresión del ingreso. Umbral 0,39.

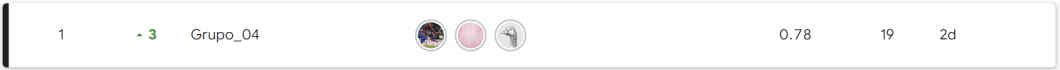
F_1 validación cruzada (5 folds)	**0,7775**
F_1 con umbral honesto	0,7775

Puesto 4 en el público → puesto 1 en el privado (+3). Elegimos por validación cruzada, no por el leaderboard público (DE ≈ 0,006): **generalizó mejor**.

Leaderboard público (20 % de test)



Leaderboard privado (80 % de test)



Datos

Datos: limpieza y nombres que se pueden leer

GEIH 2018: **543.103 personas, 164.958 hogares**; 20,0 % de hogares pobres.

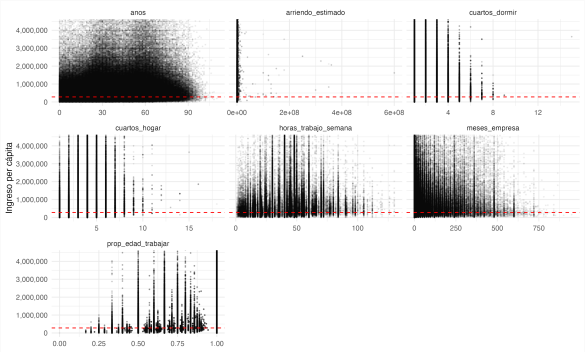
- `pobre` = ingreso per cápita (con arriendo imputado) $<$ línea: se cumple en el 100 % de los hogares.
- Los **montos de ingreso** no están en test: se eliminan de train.
- `NA` = "la pregunta no aplica" (saltos del cuestionario); no se reemplaza por 0 sin revisar.
- Sí/no a 1/0; categóricas con su código DANE *y* una dummy por categoría.
- Se eliminan 2 hogares de train con cuartos imposibles; de test, nunca.
- Base por hogar: sumas, proporciones y máximos de los miembros.

Código DANE	Nombre en las bases	Contenido
P6020	mujer	1 = mujer
P6040	anos	Años cumplidos
P6210	max_educ	Nivel educativo
P6100	regimen_salud	Contrib./subsidiado
P6430	posicion_ocupacional	Particular, cta. propia
P6800	horas_trabajo_semana	Horas normales
P6870	tamano_empresa	Tamaño de empresa
P6920	cotiza_pension	Formalidad
P7495	recibio_arriendos_pensiones	Sí/no
P5090	tenencia_vivienda	Propia, arriendo...
Clase	cabecera	1 = cabecera
Creada	arriendo_imputado	Regla DANE (98,4 %)

Estadísticas descriptivas: qué separa a los pobres

Variable (persona)	No pobres	Pobres	Dif.
Ocupado	0,508	0,304	−0,204
Educación superior	0,295	0,092	−0,203
Primaria	0,232	0,343	0,111
Vivienda propia pagada	0,427	0,294	−0,133
Vivienda sin título	0,032	0,115	0,082
Tamaño de empresa (0–9)	2,15	0,64	−1,51
Meses en la empresa	43,8	25,5	−18,3
Edad	35,7	27,3	−8,3
Prop. en edad de trabajar	0,856	0,731	−0,125
Arriendo estimado (miles)	600	278	−322

Todas las diferencias: p-valor $< 0{,}001$ (prueba t).



Lo que anticipa la comparación:

- Lo que separa es **del hogar** (cuántos trabajan, cuántos dependen): los modelos por hogar ganan.
- Relaciones **no lineales** y con umbrales (empresa, edad, arriendo): favorecen a los árboles.

Comparación de algoritmos

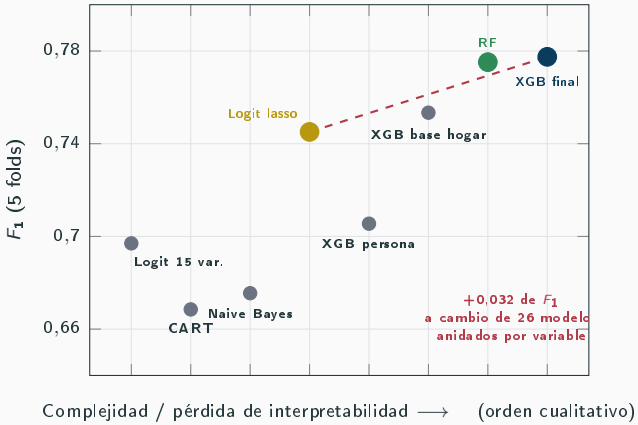
Panorama: el mejor modelo de cada categoría

Misma evaluación para todos: 5 folds por hogar, F_1 por hogar.

Categoría	Especificación	F_1	Honesto	Umbral	Escalón
CART	Por persona, 16 variables, up-sampling	0,6685	0,6679	0,62	
Naive Bayes	Por persona, 16 variables	0,6755	0,6752	0,42	por persona
XGBoost	Por persona, 24 variables	0,7055	0,7055	0,32	
Logit lasso	Por hogar, 1.159 columnas con interacciones	0,7451	0,7449	0,37	por hogar
XGBoost	Por hogar, solo la base de agregados	0,7534	0,7532	0,36	
XGBoost	Por hogar, sin Tweedie	0,7738	0,7736	0,38	
Random forest	Por hogar, variables del mejor XGBoost	0,7752	0,7750	0,40	+ modelos anidados
XGBoost final	Tweedie + regresión del ingreso	**0,7775**	**0,7775**	0,39	

Tres escalones: el salto lo da la **unidad de análisis** (persona → hogar, +0,04) y la **información** (modelos anidados, +0,02), más que el algoritmo. Kaggle de modelos del equipo: logit lasso 0,74, LightGBM 0,75.

La frontera: precisión vs. complejidad



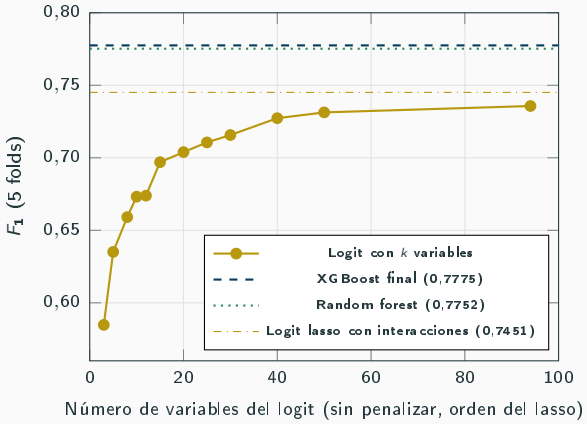
- La frontera es **cóncava**: de 0,697 (logit con 15 variables) a 0,745 (lasso) a 0,778 (XGBoost), cada punto cuesta más complejidad.
- RF y XGBoost están a 0,002 entre sí: con la misma información, el algoritmo casi no importa.
- El logit está a 0,032 del ganador con un modelo que se puede escribir en una ecuación.

Top 3: drivers, resultados y limitaciones

	XGBoost final	Random forest	Logit lasso
F_1 / umbral	**0,7775** / 0,39	0,7752 / 0,40	0,7451 / 0,37
Cómo funciona	Árboles secuenciales que corrigen el error anterior; stacking con modelos por persona	500 árboles profundos en paralelo (`mtry` 30) que se promedian	Regresión logística penalizada con interacciones y splines
Drivers	Ingreso predicho (permutarlo: $-0{,}42$ de F_1). De la persona: posición ocupacional ($-0{,}21$), arriendos/pensiones ($-0{,}06$), ingresos de inactivos ($-0{,}06$)	Las mismas variables que XGBoost (importancia propia no calculada); depende de la misma cadena de modelos anidados	Bloques: demografía 0,47 $\rightarrow$ +trabajo 0,55 $\rightarrow$ +calidad del empleo 0,62 $\rightarrow$ +salud/educación 0,67 $\rightarrow$ +vivienda/ingresos no lab. 0,73. Más predictivas: arriendo por persona, prop. contributivo
Fortalezas	Mejor F_1; estable entre particiones (DE 0,0003); 1.º en Kaggle privado	Casi el mismo F_1, menos hiperparámetros sensibles	Coeficientes con signo y magnitud; auditable; sin modelos anidados que mantener
Limitaciones	Caja negra; 26 modelos por variable; costoso de mantener y explicar	Caja negra; combinado con XGBoost no suma (0,7773): mismos errores	0,03 menos de F_1; 794 coeficientes no nulos: interpretable por bloques, no uno a uno

Logit y XGBoost tienen una correlación de **0,92** en log odds: se equivocan en los *mismos* hogares (los que están cerca de la línea).

Cuánto cuesta en F_1 un modelo que se puede leer



- **15 variables** (arriendo por persona, prop. contributivo, menores, horas, formales...): F_1 0,697.
- **40 variables**: 0,727, a 0,05 del XGBoost.
- Las interacciones del lasso suman 0,01 más; el resto de la distancia lo cubre la información anidada, no la forma funcional.
- Para un policymaker: una tabla de 15–40 coeficientes se puede publicar y discutir.

Equidad: ¿a quién excluye cada modelo?

Brecha de sensibilidad (puntos porcentuales) entre el grupo mejor y el peor detectado:

Atributo	NB	Logit	RF	XGB
Sexo del jefe	2,0	4,2	4,4	3,8
Empleo del jefe	33,4	22,2	21,4	19,7
Zona	12,9	0,0	0,2	0,8
Educación del jefe	30,6	19,3	17,7	18,0
Tamaño del hogar	38,8	25,7	21,8	22,4
Menores	31,4	23,8	19,1	19,9
Vivienda	19,9	7,2	6,2	6,4

NB: naive Bayes, como referencia. Figura completa por grupo: `output/figures/equidad_errores.png`.

- Los modelos más precisos **reducen** casi todas las brechas; entre los top 3 son parecidas.
- Todos excluyen más a los pobres con jefe formal o educado y a los hogares pequeños.
- Sexo del jefe: $\approx$4 pp en los modelos por hogar, a favor de los hogares con jefa.

Conclusión

Conclusión: interpretabilidad vs. flexibilidad

Criterio	Logit	XGBoost
F_1	0,745	**0,778**
Se explica a un beneficiario	sí	no
Auditable por un ente de control	sí	difícil
Costo de mantener y reentrenar	bajo	alto
Riesgo de manipulación	mayor	menor
Captura no linealidades	a mano	sola

Un instrumento de focalización tiene que ser **creíble**: los hogares y los entes de control deben entender por qué alguien entra o sale (Camacho y Conover, 2011; Kleinberg et al., 2015).

Recomendación de política

1. **Instrumento oficial: un logit parsimonioso** (15–40 variables del módulo laboral y la vivienda), publicable y discutible.
2. **XGBoost como auditor**: señala los hogares que el logit excluiría y que probablemente son pobres (los que "no lo parecen"), para verificarlos en campo.
3. Elegir el **umbral** según el costo social de excluir vs. incluir, no por F_1.

Para discutir: ¿cuántos puntos de F_1 vale la transparencia? ¿quién responde por el error de una caja negra?

Referencias

- Angulo, R., Díaz, Y. y Pardo, R. (2016). The Colombian Multidimensional Poverty Index: Measuring poverty in a public policy context. *Social Indicators Research*, 127(1), 1–38.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Camacho, A. y Conover, E. (2011). Manipulation of social program eligibility. *American Economic Journal: Economic Policy*, 3(2), 41–65.
- Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, 785–794.
- DANE (2019). Pobreza monetaria y multidimensional en Colombia 2018. Boletín técnico.
- Grosh, M. y Baker, J. (1995). Proxy means tests for targeting social programs. LSMS Working Paper 118, Banco Mundial.
- Kleinberg, J., Ludwig, J., Mullainathan, S. y Obermeyer, Z. (2015). Prediction policy problems. *American Economic Review*, 105(5), 491–495.
- Kleinberg, J., Mullainathan, S. y Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. *ITCS*.
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206–215.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288.