¿Por qué XGBoost? Comparación de modelos

Predicción de la pobreza monetaria con la GEIH 2018

Maria Jose Perez Juan Manuel Lozano Samuel Suárez Valle

Big Data y Machine Learning Aplicado a la Economía
Universidad de los Andes

28 de octubre de 2026

Overview: el modelo que elegimos

XGBoost por hogar

- 163 variables: base por hogar + resúmenes de modelos por persona (ingreso con pérdida Tweedie y probabilidad de ser pobre, con validación cruzada anidada).
- `eta` 0,02, profundidad 8, `min_child_weight` 50, `colsample` 0,5.
- Combinado 70/30 con una regresión del ingreso; umbral 0,39.

F_1 de validación cruzada	**0,7775**

5 folds por hogar.

Kaggle, puntaje público (20 % de test)

4	Grupo_04		0.77	19	2d

Kaggle, puntaje privado (80 % de test)

1	▲ 3	Grupo_04		0.78	19	2d

Datos: lo que hicimos distinto

GEIH 2018: 543.103 personas en 164.958 hogares, 20 % de hogares pobres. Los montos de ingreso no están en test: hay que reconstruirlos.

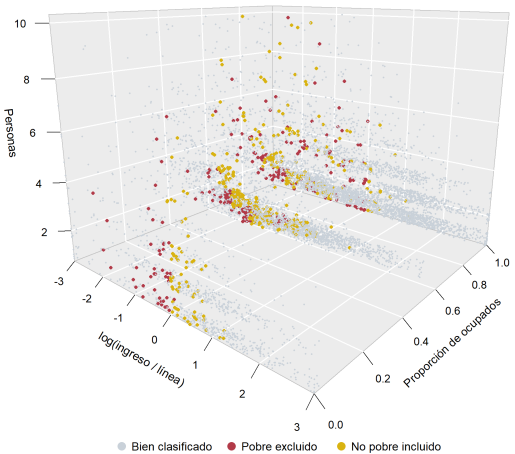
1. El hogar como unidad
Una fila por hogar con sumas, proporciones y los datos del jefe: la pobreza se define en la unidad de gasto.

2. La regla del DANE, reconstruida
El arriendo imputado (lo que el DANE suma a quien no paga arriendo) se reconstruyó con tenencia, arriendo estimado y cuota: coincide en el **98,4 %** de los hogares.

3. El ingreso como objetivo intermedio
Modelos por persona predicen el ingreso laboral y no laboral (pérdida Tweedie) y se suman en el hogar, sin usar la etiqueta del fold evaluado.

4. Preguntas añadidas en una segunda revisión
Al revisar el cuestionario agregamos preguntas que habíamos dejado por fuera: pagos en especie, búsqueda de trabajo e ingresos de desocupados e inactivos. Identifican quién recibe ingresos sin estar ocupado (R^2 del ingreso por persona 0,94 $\rightarrow$ 0,98).

Descriptivas: dónde caen los aciertos y los errores



8.000 hogares de train al azar; resultado del modelo final fuera de muestra.

Resultado	Ingreso/ línea	Prop. ocup.	Personas
Pobre detectado	0,64	0,28	4,3
Pobre excluido	0,85	0,45	3,3
No pobre incluido	1,22	0,35	3,8
No pobre bien clasif.	2,63	0,56	3,0

Ingreso/línea: mediana. Las demás: promedio.

- Los errores se apiñan **junto a la línea** ($\log = 0$): el 60 % de los pobres excluidos está a menos de 25 % de ella.
- Un pobre *excluido* se parece a un no pobre: más ocupados y un hogar más pequeño.
- Un no pobre *incluido* se parece a un pobre: menos ocupados y un hogar más grande.

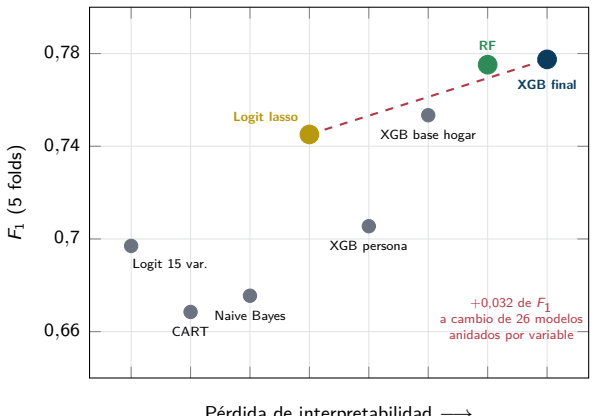
Panorama: el mejor modelo de cada categoría

Misma evaluación para todos: 5 folds por hogar, F_1 por hogar.

Categoría	Especificación	F_1	Umbral
CART	Por persona, 16 variables, up-sampling	0,6685	0,62
Naive Bayes	Por persona, 16 variables	0,6755	0,42
XGBoost	Por persona, 24 variables	0,7055	0,32
Logit lasso	Por hogar, 1.159 columnas con interacciones	0,7451	0,37
XGBoost	Por hogar, solo la base de agregados	0,7534	0,36
XGBoost	Por hogar, sin Tweedie	0,7738	0,38
Random forest	Por hogar, variables del mejor XGBoost	0,7752	0,40
XGBoost final	Tweedie + regresión del ingreso	**0,7775**	0,39

Tres escalones: por persona, por hogar y por hogar con modelos anidados. El salto lo da la **unidad de análisis** (persona → hogar, +0,04) y la **información** (modelos anidados, +0,02), más que el algoritmo. Kaggle de modelos del equipo: logit lasso 0,74, LightGBM 0,75.

La frontera: precisión vs. interpretabilidad



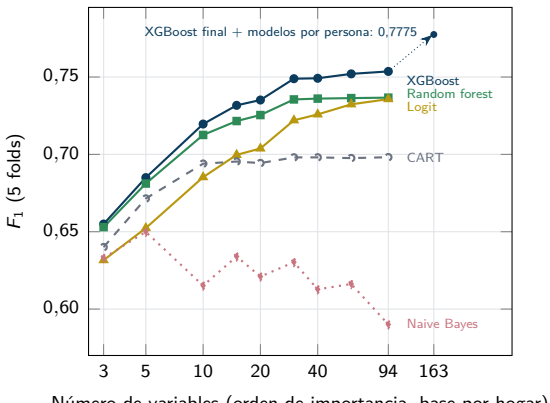
- La frontera es **cóncava**: de 0,697 (logit con 15 variables) a 0,745 (lasso) a 0,778 (XGBoost), cada punto cuesta más interpretabilidad.
- RF y XGBoost están a 0,002 entre sí: con la misma información, el algoritmo casi no importa.
- El logit está a 0,032 del ganador con un modelo que se puede escribir en una ecuación.

Top 3: cómo funcionan, resultados y limitaciones

	XGBoost final	**Random forest**	**Logit lasso**
F_1 / AUC	**0,7775** / 0,959	0,7752 / 0,958	0,7451 / 0,946
Cómo funciona	Árboles secuenciales que corrigen el error anterior; stacking con modelos por persona	500 árboles profundos en paralelo que se promedian	Regresión logística penalizada con interacciones
Qué lo mueve	Ingreso predicho por persona; posición ocupacional	Las mismas variables que XGBoost	Arriendo por persona, afiliación contributiva, horas
Fortalezas	Mejor F_1; estable entre particiones; 1.º en Kaggle privado	Casi el mismo F_1 con menos hiperparámetros sensibles	Coeficientes con signo y magnitud; auditable
Limitaciones	Caja negra; 26 modelos por variable; costoso de mantener y explicar	Caja negra; combinado con XGBoost no suma: mismos errores	0,03 menos de F_1; 794 coeficientes: se lee por bloques

Logit y XGBoost tienen una correlación de **0,92** en log odds: se equivocan en los *mismos* hogares, los que están cerca de la línea.

Cuánto cuesta en F_1 un modelo que se puede leer



- Cada algoritmo usa las k variables más importantes de la base por hogar, en el mismo orden y con los mismos folds.
- Las curvas son **cóncavas**: con 15 variables el logit ya llega a 0,70 y XGBoost a 0,73; desde 30, los árboles casi no suben.
- Con 94 variables: logit 0,736, RF 0,737, XGBoost 0,754. El algoritmo vale ≈0,02; los modelos anidados, otros 0,02.
- Naive Bayes **empeora** con más variables: cuenta dos veces la información de las correlacionadas.

Matriz de confusión: los tres mejores modelos

XGBoost final

	predicción: pobre	predicción: no pobre
Pobre	**26.635** 80,7 %	**6.389** 19,3 %
No pobre	**8.854** 6,7 %	**123.080** 93,3 %

Random forest

	predicción: pobre	predicción: no pobre
Pobre	**26.591** 80,5 %	**6.433** 19,5 %
No pobre	**8.993** 6,8 %	**122.941** 93,2 %

Logit lasso

	predicción: pobre	predicción: no pobre
Pobre	**26.155** 79,2 %	**6.869** 20,8 %
No pobre	**11.026** 8,4 %	**120.908** 91,6 %

- Filas: la realidad (33.024 hogares pobres y 131.934 no pobres de train). Columnas: la predicción fuera de muestra, con el umbral de cada modelo. Porcentaje de la fila.
- **Rojo**: pobres excluidos (error de exclusión). **Amarillo**: no pobres incluidos (error de inclusión).
- XGBoost y RF son casi idénticos. Frente al logit, XGBoost excluye **480 pobres menos** e incluye **2.172 no pobres menos**.

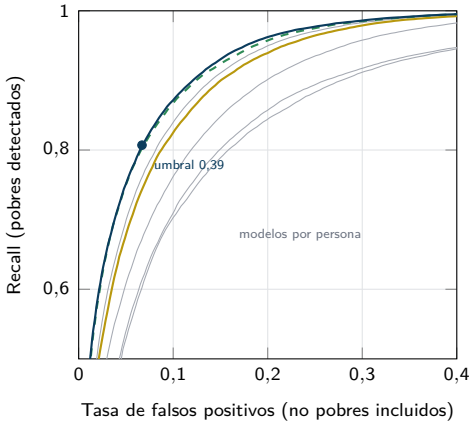
Métricas de los 8 modelos

Modelo	Precisión	Recall	Accuracy	F_1	AUC
CART (persona)	0,642	0,698	0,862	0,669	0,895
Naive Bayes (persona)	0,630	0,729	0,860	0,676	0,903
XGBoost (persona)	0,656	0,763	0,872	0,706	0,929
Logit lasso	0,703	0,792	0,892	0,745	0,946
XGBoost base hogar	0,707	0,807	0,894	0,753	0,951
XGBoost sin Tweedie	0,739	0,812	0,905	0,774	0,958
Random forest	0,747	0,805	0,906	0,775	0,958
XGBoost final	**0,751**	0,807	**0,908**	**0,778**	**0,959**

Precisión, recall y accuracy con todos los hogares; F_1 promedio de los 5 folds.

- **Precisión**: de los predichos pobres, cuántos lo son. **Recall**: de los pobres, cuántos se detectan.
- Entre los modelos por hogar el recall es casi igual ($\approx$0,80): la ganancia está en la **precisión** (0,70 $\rightarrow$ 0,75), es decir, en incluir menos no pobres.
- La accuracy engaña: decir "nadie es pobre" ya da 0,80.

Curvas ROC: ordenar a los hogares, sin umbral



Modelo	AUC
XGBoost final (—)	**0,959**
Random forest (- - -)	0,958
Logit lasso (—)	0,946
XGBoost base hogar	0,951
XGBoost por persona	0,929
Naive Bayes, CART	0,903 / 0,895

- AUC: probabilidad de que un pobre tenga un puntaje mayor que un no pobre. No depende del umbral.
- Los tres primeros casi empatan en AUC: **ordenan** igual de bien; la diferencia está en la zona del umbral.

Equidad: ¿a quién excluye cada modelo?

Cómo se mide. Para cada grupo de hogares (por ejemplo, jefe formal) se calcula el **recall**: el % de sus hogares pobres que el modelo detecta. La **brecha** de un atributo es el recall del grupo más detectado menos el del menos detectado, en puntos porcentuales.

	Recall del XGBoost final por grupo		Brecha (pp)			
Atributo	Menos detectado	Más detectado	XGB	RF	Logit	NB
Empleo del jefe	Formal: 65,1 %	No ocupado: 84,8 %	19,7	21,4	22,2	33,4
Educación del jefe	Superior: 65,4 %	Primaria o menos: 83,4 %	18,0	17,7	19,3	30,6
Tamaño del hogar	1 o 2 personas: 66,5 %	5 o más: 88,8 %	22,4	21,8	25,7	38,8
Menores	Sin menores: 65,2 %	Con menores: 85,1 %	19,9	19,1	23,8	31,4
Vivienda	Propia: 78,2 %	Usufructo u otra: 84,5 %	6,4	6,2	7,2	19,9
Sexo del jefe	Hombre: 78,9 %	Mujer: 82,7 %	3,8	4,4	4,2	2,0
Zona	Rural: 80,0 %	Cabecera: 80,8 %	0,8	0,2	0,0	12,9

- Todos los modelos excluyen más a los pobres "que no lo parecen": jefe formal o educado, hogares pequeños o sin menores.
- Los modelos más precisos **reducen** casi todas las brechas; entre los tres mejores son parecidas.

Conclusión: interpretabilidad vs. flexibilidad

Criterio	Logit	XGBoost
F_1	0,745	**0,778**
Se explica a un beneficiario	sí	no
Auditable por un ente de control	sí	difícil
Costo de mantener y reentrenar	bajo	alto
Riesgo de manipulación	mayor	menor
Captura no linealidades	a mano	sola

Un instrumento de focalización tiene que ser **creíble**: los hogares y los entes de control deben entender por qué alguien entra o sale (Camacho y Conover, 2011; Kleinberg et al., 2015).

Recomendación de política

1. **Instrumento oficial: un logit parsimonioso** (15–40 variables del módulo laboral y la vivienda), publicable y discutible.
2. **XGBoost como auditor**: señala los hogares que el logit excluiría y que probablemente son pobres, para verificarlos en campo.
3. Elegir el **umbral** según el costo social de excluir frente a incluir, no por F_1.

Para discutir: ¿cuántos puntos de F_1 vale la transparencia? ¿Quién responde por el error de una caja negra?

Referencias

Angulo, R., Díaz, Y. y Pardo, R. (2016). The Colombian Multidimensional Poverty Index: Measuring poverty in a public policy context. *Social Indicators Research, 127*(1), 1–38.

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32.

Camacho, A. y Conover, E. (2011). Manipulation of social program eligibility. *American Economic Journal: Economic Policy, 3*(2), 41–65.

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD* (pp. 785–794).

DANE (2019). *Pobreza monetaria y multidimensional en Colombia 2018* [Boletín técnico].

Grosh, M. y Baker, J. (1995). *Proxy means tests for targeting social programs* (LSMS Working Paper 118). Banco Mundial.

Kleinberg, J., Ludwig, J., Mullainathan, S. y Obermeyer, Z. (2015). Prediction policy problems. *American Economic Review, 105*(5), 491–495.

Kleinberg, J., Mullainathan, S. y Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. En *8th Innovations in Theoretical Computer Science Conference (ITCS)*.

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence, 1*(5), 206–215.

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B, 58*(1), 267–288.